

# Probabilidade e Estatística Matemática

Ano 2022 - Módulo 4 - Aula 1 (Parte 1/2)

Paulo Justiniano Ribeiro Jr

Programa de Pós Graduação  
Métodos Numéricos em Engenharia  
Universidade Federal do Paraná

10 de agosto de 2022

# Exemplo: O problema dos testes de diagnóstico


Informação disponível:

- ▶ Teste de varredura (*screening*) para uma determinada doença
- ▶ Testes são *imperfeitos*, suponha que:  
acerta 90% dos que tem doença e 80% dos que não tem.
- ▶ A doença ocorre em 2% da população


Pergunta de interesse:

Se uma pessoa testou positivo, qual a chance de ter a doença?

# Teste de diagnóstico

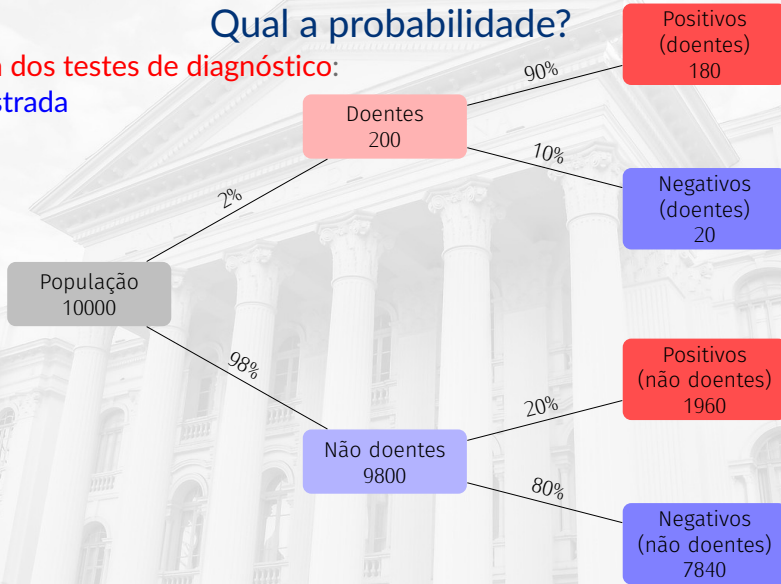


# Teste de diagnóstico



# Qual a probabilidade?

O problema dos testes de diagnóstico:  
Solução ilustrada



# Qual a probabilidade?

## Terminologia específica:

- ▶ Teste de *screening* para uma determinada doença
- ▶ Teste *imperfeito*:  
acerta 90% dos que tem doença (*sensibilidade*) e portanto 10% de *falso negativo*  
acerta 80% dos que não tem (*especificidade*) e portanto 20% de *falso positivo*
- ▶ A doença ocorre em 2% da população (*prevalência*)

## Pergunta de interesse:

Se uma pessoa testou positivo, qual a chance de ter a doença?  
(*valor preditivo positivo*)

# Testes de diagnóstico - Organizando dados tabelas

Características do teste (para diagnósticos conhecidos)

|           | Positivo | Negativo |   |
|-----------|----------|----------|---|
| c/ Doença | 0,90     | 0,10     | 1 |
| s/ Doença | 0,20     | 0,80     | 1 |

Temos 2% com a doença na população (e portanto 98% sem)

|           | Positivo | Negativo | Total |
|-----------|----------|----------|-------|
| c/ Doença | 0,018    | 0,002    | 0,02  |
| s/ Doença | 0,196    | 0,784    | 0,98  |
| Total     | 0,214    | 0,786    | 1     |

Conhecendo o resultado do teste

|           | Positivo | Negativo |  |
|-----------|----------|----------|--|
| c/ Doença | 0.0841   | 0.00254  |  |
| s/ Doença | 0.916    | 0.997    |  |
| Total     | 1        | 1        |  |

# Testes de diagnóstico

A notação é nossa amiga!

$$P[+|D] = 0,90 \longrightarrow P[-|D] = 0,10$$

$$P[-|\bar{D}] = 0,80 \longrightarrow P[+|\bar{D}] = 0,20$$

$$P[D] = 0,02$$

$$P[D|+] = ?$$

E um Teorema resolve o problema!

$$\begin{aligned} P[D|+] &= \frac{P[+|D] \cdot P[D]}{P[+|D] \cdot P[D] + P[+|\bar{D}] \cdot P[\bar{D}]} \\ &= \frac{0,90 \cdot 0,02}{0,90 \cdot 0,02 + 0,20 \cdot 0,98} = 0,0841 \end{aligned}$$



# Testes de diagnóstico

Solução ilustrada (com notação)

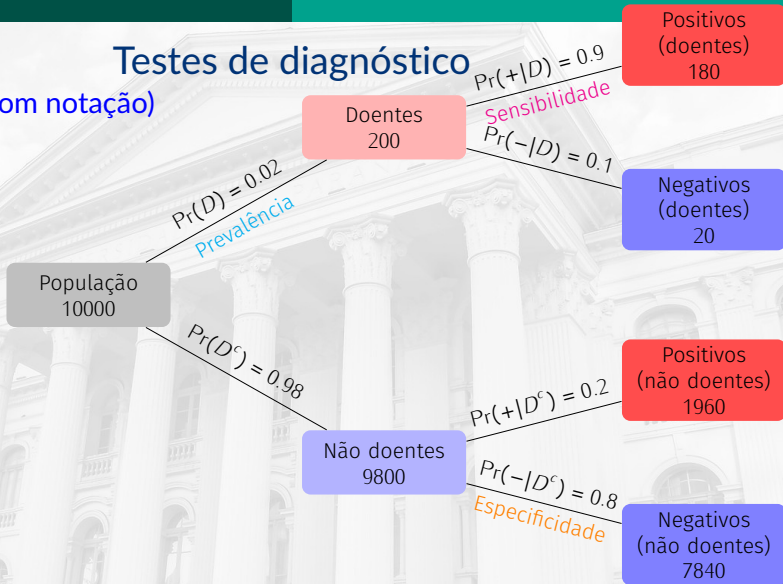


Figura 2. Ilustração do problema do teste de diagnóstico

# Atualização de informação

- ▶ Existência de uma probabilidade inicial (*a priori*).

| Estado        | Doente ( $D$ ) | Sadio ( $\bar{D}$ ) |
|---------------|----------------|---------------------|
| Probabilidade | 0,02           | 0,98                |

- ▶ Informação

Teste positivo e  $P[+|D] = 0,90$  e  $P[+|\bar{D}] = 0,20$

- ▶ (possivelmente) alterando probabilidades (*a posteriori*).

| Estado        | Doente ( $D$ ) | Sadio ( $\bar{D}$ ) |
|---------------|----------------|---------------------|
| Probabilidade | 0.0841         | 0.916               |

- ▶ Classificação de possíveis *estados da natureza* e suas probabilidades.
- ▶ Decisão guiada pela probabilidade.

# Adaptando notação

- Existência de uma probabilidade inicial (*a priori*).

| Estado        | $\theta = 1$ (Doente) | $\theta = 0$ (Sadio) |
|---------------|-----------------------|----------------------|
| Probabilidade | 0,02                  | 0,98                 |

- Dado/Informação  $Y = 1$  se positivo,  $Y = 0$  se negativo,  
Teste positivo e  $P[Y = 1|\theta = 1] = 0,90$  e  $P[Y = 1|\theta = 0] = 0,20$

- atualizando probabilidades (*a posteriori*).

| Estado        | $\theta = 1$ (Doente) | $\theta = 0$ (Sadio) |
|---------------|-----------------------|----------------------|
| Probabilidade | 0.0841                | 0.916                |

- Distribuição de probabilidades dos *valores do parâmetro* e suas probabilidades.

# Teorema de Bayes

Reescrevendo e reinterpretando como problema de classificação

$$P[A_j|B] = \frac{P[B|A_j] \cdot P[A_j]}{\sum_j P[B|A_j] \cdot P[A_j]} \propto P[B|A_j] \cdot P[A_j]$$

Como o paciente deve ser classificado após o teste?

$$P[A_1|B] \propto P[B|A_1] \cdot P[A_1] \text{ (ou, } P[D|+] \propto P[+|D] \cdot P[D])$$

$$P[A_2|B] \propto P[B|A_2] \cdot P[A_2] \text{ (ou, } P[\bar{D}|+] \propto P[+|\bar{D}] \cdot P[\bar{D}])$$

Portanto

$$P[A_1|B] \propto 0,9 \cdot 0,02 = 0,018$$

$$P[A_2|B] \propto 0,2 \cdot 0,98 = 0,196$$

$A_1$  e  $A_2$  são todas as categorias possíveis, as probabilidades devem somar 1:

$$P[A_1|B] = \frac{0,018}{0,018 + 0,196} = 0,084$$

$$P[A_2|B] = \frac{0,196}{0,018 + 0,196} = 0,916$$

# Teorema de Bayes

E se o teste for repetido?

Notação:  $B_1$  positivo no primeiro teste e  $B_2$  positivo no segundo teste

Supondo independência

$$P[A_1|B_1, B_2] \propto P[B_2|A_1] \cdot P[B_1|A_1] \cdot P[A_1]$$

$$P[A_2|B_1, B_2] \propto P[B_2|A_2] \cdot P[B_1|A_2] \cdot P[A_2]$$

Portanto se for o mesmo teste (mesmas características de sensibilidade e especificidade)

$$P[A_1|B] \propto 0,90^2 \cdot 0,02 = 0,0162$$

$$P[A_2|B] \propto 0,20^2 \cdot 0,98 = 0,0392$$

Logo,

$$P[A_1|B] = \frac{0,0162}{0,0162 + 0,0392} = 0,292 \quad P[A_2|B] = \frac{0,0392}{0,0162 + 0,0392} = 0,708$$

A classificação ainda é a mesma mas as chances mudaram!

Com três testes positivos  $P[A_1|B] = 0.65$ .

## Repetindo o teste - resumo

Estados da natureza:

| Estado ( $\theta$ ) | $\theta = 0(\bar{D})$ | $\theta = 1(D)$ |
|---------------------|-----------------------|-----------------|
| Probabilidade       | 0,98                  | 0,02            |

Estados da natureza após primeiro exame positivo:

| Estado ( $\theta y_1$ ) | $\theta = 0(\bar{D})$ | $\theta = 1(D)$ |
|-------------------------|-----------------------|-----------------|
| Probabilidade           | 0,916                 | 0,084           |

Estados da natureza após segundo exame positivo:

| Estado ( $\theta y_1, y_2$ ) | $\theta = 0(\bar{D})$ | $\theta = 1(D)$ |
|------------------------------|-----------------------|-----------------|
| Probabilidade                | 0,708                 | 0,292           |

# Teorema de Bayes

Testes positivos e negativos?

Notação:  $B_1$  positivo no primeiro teste, e  $B_2$  negativo no segundo teste e  $B_3$  positivo no terceiro teste.

Supondo independência:

$$P[A_1|B_1, \bar{B}_2, B_3] \propto P[B_3|A_1] \cdot P[\bar{B}_2|A_1] \cdot P[B_1|A_1] \cdot P[A_1]$$

$$P[A_2|B_1, \bar{B}_2, B_3] \propto P[B_3|A_2] \cdot P[\bar{B}_2|A_2] \cdot P[B_1|A_2] \cdot P[A_2]$$

Portanto se for o mesmo teste (mesmas características de sensibilidade e especificidade),

$$P[A_1|B] \propto 0,90 \cdot 0,10 \cdot 0,90 \cdot 0,02 = 0.00162$$

$$P[A_2|B] \propto 0,20 \cdot 0,80 \cdot 0,20 \cdot 0,98 = 0.0314$$

Logo,

$$P[A_1|B] = \frac{0.00162}{0.00162 + 0.0314} = 0.0491 \quad P[A_2|B] = \frac{0.0314}{0.00162 + 0.0314} = 0.951$$

# O problema dos testes de diagnóstico

E se o teste tivesse sido feito por recomendação médica após um exame?

Mudaria algo?

Baseado em sua experiência o médico estima que 30% dos pacientes com os sintomas apresentados tem a doença.

Solução? (reproduzir passos acima!)

Neste caso:

$$\begin{aligned} P[D|+] &= \frac{P[+|D] \cdot P[D]}{P[+|D] \cdot P[D] + P[+|\bar{D}] \cdot P[\bar{D}]} \\ &= \frac{0,90 \cdot 0,30}{0,90 \cdot 0,30 + 0,20 \cdot 0,70} = 0.659 \end{aligned}$$

Comparação e *interpretação* (e ...muito cuidado!)



# Atualização de informação

- ▶ Existência de uma probabilidade inicial (*a priori*).

| Estado        | $\theta = 1$ (Doente) | $\theta = 0$ (Sadio) |
|---------------|-----------------------|----------------------|
| Probabilidade | 0,30                  | 0,70                 |

- ▶ Informação

Teste positivo e  $P[Y = 1|\theta = 1] = 0,90$  e  $P[Y = 1|\theta = 0] = 0,20$

- ▶ (possivelmente) alterando probabilidades (*a posteriori*).

| Estado        | $\theta = 1$ (Doente) | $\theta = 0$ (Sadio) |
|---------------|-----------------------|----------------------|
| Probabilidade | 0.659                 | 0.341                |

# Teorema de Bayes

$$P[A_j|B] = \frac{P[B|A_j] \cdot P[A_j]}{\sum_j P[B|A_j] \cdot P[A_j]}$$

- ▶ No exemplo só haviam duas categorias:

$A_1(D)$  : com a doença,  $A_2(\bar{D})$  : sem a doença.

- ▶ O resultado é mais geral, válido para várias categorias.
- ▶ Categorias são possíveis **estados do sistema**:
  - ▶ **estados do sistema** podem ser categóricos (ou ainda discretos ou enumeráveis),
  - ▶ **estados do sistema** podem ser em uma escala contínua.

# Teorema de Bayes

$$P[\theta_j|Y] = \frac{P[Y|\theta_j] \cdot P[\theta_j]}{\sum_j P[Y|\theta_j] \cdot P[\theta_j]}$$

- ▶ No exemplo só haviam duas categorias:

$\theta = 1(D)$  : com a doença,  $\theta = 0(\bar{D})$  : sadio.

- ▶ O resultado é mais geral, válido para várias categorias ( $j = 2, 3, 4, \dots$ ).
- ▶ Categorias são possíveis **valores do parâmetro**:
  - ▶ **valores do parâmetro** podem ser categóricos (ou ainda discretos ou enumeráveis),
  - ▶ **valores do parâmetro** podem ser em uma escala contínua:

$$f(\theta|y) = \frac{f(y|\theta) \cdot f(\theta)}{\int f(y|\theta) \cdot f(\theta) d\theta}.$$

## Exemplo: estimando uma proporção

Em uma população (considerada *infinita*) uma proporção  $\theta$  de indivíduos apresenta determinada característica.

Deseja-se (**inferências**):

- ▶ estimar  $\theta$ ,
- ▶ expressar a incerteza sobre esta estimativa,
- ▶ verificar se  $\theta$  (e portanto a população) está fora de normas/referências (proporção max. de 20%), se há evidências de um desvio “relevante” (significativo).

Dados de *uma* amostra (considerada aleatória):

$n = 80$  e  $y = 19$

Como proceder?

# Objetivos de inferência

## ► Problema, decisão e evidência.

- Em uma população (considerada *infinita*) uma proporção  $\theta$  de indivíduos apresenta determinada característica. Deseja-se saber se  $\theta$  ultrapassa 0,20 (20%).
- Dados de *uma* amostra (considerada aleatória):  $n = 80$  e  $y = 19$ .

## ► Deseja-se (**inferências**).

- Estimar  $\theta$ , obtendo da amostra uma *estimativa*  $\hat{\theta}$ ,
- Expressar a incerteza sobre esta estimativa,
- Avaliar se  $\theta$  (e portanto “o estado” da população) está fora do valor referência (proporção max. de 20%), se há evidências de um desvio “relevante” (*significativo*).

## ► Como proceder?

- Princípios gerais (paradigma(s)) a serem seguidos?

# Aprendizado estatístico

## Questões:

- ▶ O que os dados dizem?
- ▶ Em que devo acreditar?
- ▶ O que devo fazer?

## Objetivos:

Estimativa de  $\theta$ ,  
expressão da incerteza,  
opinião em relação a valor de interesse  $\theta_0 = 0,20$

## O que os dados dizem?

Se a proporção é  $\theta$ , podemos avaliar a chance (probabilidade) de obter um certo número  $Y$  de indivíduos com a característica em uma amostra de  $n$  indivíduos. Sob certas suposições é razoável adotar:

$$P[Y = y|\theta] = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

Quando obtemos a amostra temos  $n = 80$  e  $y = 19$ . Para cada  $\theta$  temos então a chance de obter esta amostra.


$$P[Y = y|\theta] = \binom{80}{19} \theta^{19} (1 - \theta)^{80-19}$$

Como esta chance muda para cada valor de  $\theta$ ?

Considerando todos os  $\theta$  possíveis temos uma função de  $\theta$ :

$$L[\theta|y] = \binom{80}{19} \theta^{19} (1 - \theta)^{80-19}$$

# Uma função representando ideias




## Objetivos:

- Estimativa de  $\theta$ ,
- expressão da incerteza,
- opinião em relação a valor de interesse  $\theta_0 = 0,20$




# Uma função representando ideias



## Objetivos:

- Estimativa de  $\theta$  → expressão da incerteza,
  - opinião em relação a valor de interesse
- $\theta_0 = 0,20$


# Uma função representando ideias



**Objetivos:**

- Estimativa de  $\theta$ ,
- expressão da incerteza

# Uma função representando ideias



## Objetivos:

- Estimativa de  $\theta$ ,
- expressão da incerteza,
- **opinião em relação a valor de interesse**

$$\theta_0 = 0, 20$$

# Suposições e considerações adicionais

## ► Suposições

- amostra aleatória (independência)
- população *infinita*
- modelo binomial (critério de parada:  $n$  fixo) e invariância

## ► Critérios necessários

- onde efetuar o corte da função para determinar faixas de incerteza?
- como avaliar o valor de verossimilhança (relativa) para  $\theta_0$ ?

# Suposições e considerações adicionais

## ► Suposições:

- amostra aleatória (independência),
- população *infinita*,
- modelo binomial (critério de parada:  $n$  fixo) e invariância.

## ► Critérios necessários:

- onde efetuar o corte da função para determinar faixas de incerteza,
- como avaliar o valor de verossimilhança (relativa) para  $\theta_0$ ,

## ► Indo além dos dados.

- Não há ou não se usa nenhuma informação “acessória/preliminar” sobre  $\theta$ ?
- Como se comportariam outras amostras que fossem eventualmente tomadas?
- Questões motivam e caracterizam diferentes abordagens!

# Inferência Bayesiana

O objeto de inferência é a **distribuição à posteriori**

- ▶ A incerteza inicial sobre  $\theta$  é expressa na forma de uma distribuição **priori** para  $\theta$
- ▶ Com amostra **atualizamos** opinião  $\theta$  com a informação contida na **verossimilhança**
- ▶ O conhecimento/incerteza atualizados sobre  $\theta$  é expresso pela distribuição **posteriori**

Formalmente:

$$f(\theta|y) \propto f(\theta) \cdot L(\theta|y)$$

ou, usando jargão técnico:

$$\text{posteriori} \propto \text{priori} \cdot \text{verossimilhança}$$

# A essência de Bayes ilustrada (I)

Exemplo I : estimação da proporção de atributo ( $\theta$ ) na população

- **Priori:** Acredita-se que o atributo ocorre em 40% da população com 70% de chance de estar entre 30 e 50%.

Informação expressa como distribuição de probabilidades para  $\theta$ :

$$[\theta] \sim \text{Beta}(10; 15) \longrightarrow f(\theta) = C \theta^{10-1} (1 - \theta)^{15-1}$$

- **Verossimilhança:** Modelo Binomial, amostra  $n=80$  e  $y=19$


$$L[\theta] = \binom{80}{19} \theta^{19} (1 - \theta)^{80-19}$$

- **Posteriori:** a distribuição de probabilidades para  $\theta$  após observar os dados:

$$[\theta|y] \sim \text{Beta}(29; 76) \longrightarrow f(\theta|y) = C \theta^{29-1} (1 - \theta)^{76-1}$$

$C$  é um valor constante conhecido.

# A essência de Bayes ilustrada (I)





# A essência de Bayes ilustrada (I)

```
(prI <- prioriBeta(0.4, c(0.30, 0.50), 0.70))  
##      alpha      beta  
## 9.912277 14.868415  
postBinom(19, 80, prI, plot=FALSE)  
## $pars  
##           alpha      beta  
## priori      9.912277 14.86842  
## posteriori 28.912277 75.86842  
##  
## $summary  
##           moda      media  variancia  
## priori      0.3912206 0.4000000 0.009309292  
## posteriori 0.2715712 0.2759313 0.001888750  
##  
## $EMV  
## [1] 0.2375
```

## A essência de Bayes ilustrada (II)

Uma priori bem diferente:

- **Priori:** Acredita-se que o atributo ocorre em 8% da população com 90% de chance de estar entre 3 e 20%.

$$[\theta] \sim \text{Beta}(2; 24) \longrightarrow f(\theta) = C \theta^{2-1} (1 - \theta)^{24-1}$$

- **Verossimilhança:** Modelo Binomial, amostra  $n=80$  e  $y=19$


$$L[\theta] = \binom{80}{19} \theta^{19} (1 - \theta)^{80-19}$$

- **Posteriori:** após observar os dados:

$$[\theta|y] \sim \text{Beta}(21; 85) \longrightarrow f(\theta|y) = C \theta^{21-1} (1 - \theta)^{85-1}$$

$C$  é um valor constante conhecido.

## A essência de Bayes ilustrada (II)



## A essência de Bayes ilustrada (II)

```
(prII <- prioriBeta(0.08, c(0.03, 0.20), 0.90))  
##      alpha      beta  
## 2.124901 24.436358  
postBinom(19, 80, prII, plot=FALSE)  
## $pars  
##           alpha      beta  
## priori      2.124901 24.43636  
## posteriori 21.124901 85.43636  
##  
## $summary  
##           moda      media  variancia  
## priori      0.0457998 0.0800000 0.002670415  
## posteriori 0.1924700 0.1982418 0.001477688  
##  
## $EMV  
## [1] 0.2375
```

## A essência de Bayes ilustrada (III)

Uma **priori vaga** :

- **Priori**: Não se sabe praticamente nada sobre  $\theta$ . Expressa-se então que o atributo ocorre em 50% da população mas com 90% de chance de estar entre 5 e 95%.

$$[\theta] \sim \text{Beta}(1.2, 1.2) \longrightarrow f(\theta) = C \theta^{1.2-1} (1 - \theta)^{1.2-1}$$

- **Verossimilhança**: Modelo Binomial, amostra  $n=80$  e  $y=19$


$$L[\theta] = \binom{80}{19} \theta^{19} (1 - \theta)^{80-19}$$

- **Posteriori**: após observar os dados:

$$[\theta|y] \sim \text{Beta}(20, 62) \longrightarrow f(\theta|y) = C \theta^{20-1} (1 - \theta)^{62-1}$$

$C$  é um valor constante conhecido.

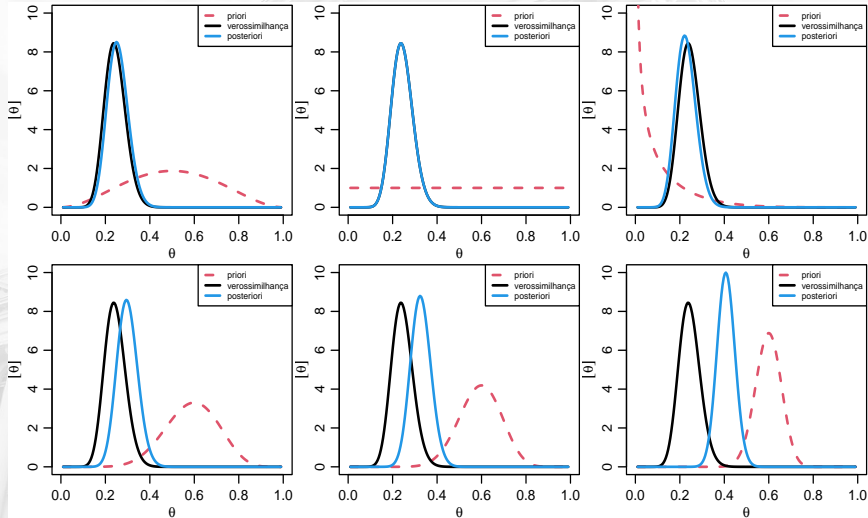
## A essência de Bayes ilustrada (III)



## A essência de Bayes ilustrada (III)

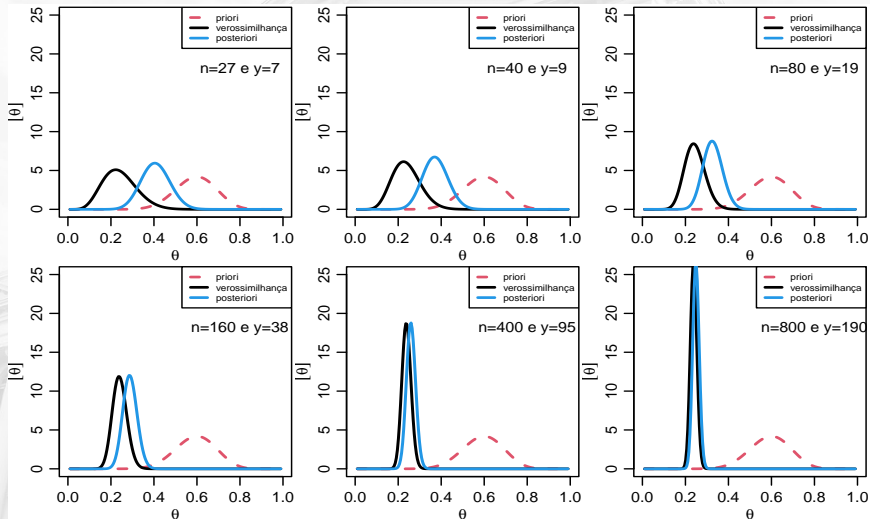
```
(prIII <- prioriBeta(0.50, c(0.05, 0.95), 0.90))  
##      alpha      beta  
## 1.170088 1.170088  
postBinom(19, 80, prIII, plot=FALSE)  
## $pars  
##           alpha      beta  
## priori      1.170088 1.170088  
## posteriori 20.170088 62.170088  
##  
## $summary  
##           moda      media  variancia  
## priori      0.5000000 0.5000000 0.074846333  
## posteriori 0.2386115 0.2449605 0.002219276  
##  
## $EMV  
## [1] 0.2375
```

# Efeito da priori (fixando amostra)





## Efeito do tamanho da amostra (fixando priori)



# Comentários

- ▶ Expressão da opinião “a priori” é necessária e sua especificação é um desafio.
- ▶ As interpretações de intervalo de confiança são agora probabilísticas, por exemplo pode-se avaliar intervalo (de credibilidade) para uma certa probabilidade:

$$P[a < \theta < b] = 0.95.$$

- ▶ No contexto do exemplo, pode-se avaliar

$$P[\theta \geq 0, 20].$$

# Inferência Bayesiana

Em resumo:

- ▶ **Estimativa de  $\theta$** : alguma medida resumo da posteriori (média, moda, mediana, ...)
- ▶ **expressão da incerteza**: variabilidade da distribuição posteriori
- ▶ **opinião em relação a valor de interesse  $\theta \geq 0.20$** : probabilidade na posteriori