

# Estatística Inferencial

Prof. Wagner Hugo Bonat

Departamento de Estatística  
Universidade Federal do Paraná





# Principais modelos multivariados

# Importância das distribuições multivariadas

- ▶ Descrevem o comportamento conjunto de várias variáveis aleatórias.
- ▶ Permite analisar de forma simultânea várias variáveis aleatórias.
- ▶ Investigar a relação entre elas.
- ▶ Usar a informação de uma para inferir sobre a outra.
- ▶ Descrever estruturas de dependência temporal, espacial, genética, etc.
- ▶ Condensar a informação de várias variáveis em um número reduzido de fatores latentes.

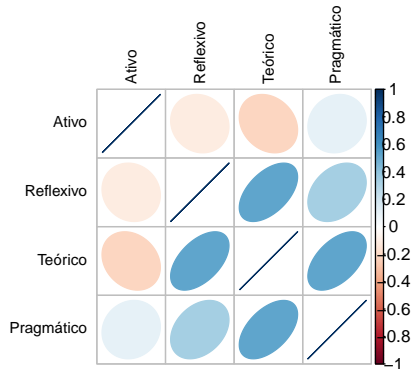


Figura 1. Correlação entre os escores para os estilos de aprendizagem determinados para os alunos de Estatística Básica.



# A distribuição Multinomial

# Características de uma v.a. Multinomial

- ▶ **Generalização** da distribuição Binomial.
  - ▶ Binomial: 2 resultados mutuamente exclusivos  $\{0, 1\}$ .
  - ▶ Multinomial:  $k$  resultados mutuamente exclusivos.
- ▶ Condições:
  - ▶ Suponha  $n$  ensaios **independentes** que podem apresentar, em cada, apenas um de  $k$  possíveis resultados  $\{O_1, O_2, \dots, O_k\}$ .
  - ▶ Sejam  $p_1, p_2, \dots, p_k$ , com  $\sum p_i = 1$ , as probabilidades de observar  $O_1, O_2, \dots, O_k$ , respectivamente, que se mantêm **constantes**.
  - ▶ Seja  $Y_i$  o **número de vezes** que o resultado  $O_i$  ocorre nos  $n$  ensaios.
  - ▶ Dessa forma,  
 $\{Y_1, \dots, Y_k\} \sim \text{Multinomial}(p_1, \dots, p_k, n)$ .

$j$	$O_1$	$O_2$	$\dots$	$O_k$
1		✓		
2	✓			
3		✓	$\vdots$	
$\vdots$				✓
$n$		✓		
Soma	$Y_1$	$Y_2$	$\dots$	$Y_k$

# Exemplos de uma v.a. Multinomial

1. Resultado do arremesso da bola à cesta:

{errou, fez 1, fez 2, fez 3 pontos}.

2. Ação resultado de uma propaganda direta por email

{não viu, acessou, wishlist, compra}.

3. Categoria de veículo alugado por cliente em um site

{SUV, Sedan, Hatch, Utilitário, ...}.

4. Classificação de um estudante em relação à área do Curso

{Exatas, Humanas, Biológicas}.

5. Signo de uma pessoa.

6. Dia da semana de acidente de trabalho.

7. Grau de uma infração de trânsito.

8. Estado civil de uma pessoa.

# A distribuição Multinomial

Satisfeitas as condições apresentadas anteriormente, tem-se que a distribuição do vetor aleatório  $\{Y_1, \dots, Y_k\}$  é dada por

$$\begin{aligned} p(y_1, \dots, y_k) &= \frac{n!}{y_1! \cdot \dots \cdot y_k!} \cdot p_1^{y_1} \cdot \dots \cdot p_k^{y_k} \\ &= \frac{n!}{\prod_{i=1}^k y_i!} \cdot \prod_{i=1}^k p_i^{y_i}. \end{aligned}$$

Esperança e variância para cada componente  $i$  é dado por

$$\begin{aligned} E(O_i) &= p_i & \text{logo} & \quad E(Y_i) = n \cdot p_i. \\ V(O_i) &= p_i(1 - p_i) & \text{logo} & \quad V(Y_i) = n \cdot p_i(1 - p_i). \end{aligned}$$

$j$	$O_1$	$O_2$	$\dots$	$O_k$
1		✓		
2	✓			
3		✓	$\vdots$	
$\vdots$				
$n$		✓		✓
Soma	$Y_1$	$Y_2$	$\dots$	$Y_k$

## Exemplo: bolas de gude

Em uma urna há 2 bolas vermelhas, 3 verdes e 5 azuis. São selecionadas 4 bolas ao acaso da urna com reposição. Qual a probabilidade de retirar 2 verdes e 2 azuis.



Figura 2. Bolas de gude. Fonte: <https://cutt.ly/QhzaxK8>.



# Solução

- ▶ São  $n = 4$  ensaios independentes.
- ▶ As probabilidades são:

$$p_1 = \frac{2}{10}, \quad p_2 = \frac{3}{10} \quad \text{e} \quad p_3 = \frac{5}{10}.$$

- ▶ Deseja-se a probabilidade do resultado

$$y_1 = 0, \quad y_2 = 2 \quad \text{e} \quad y_3 = 2.$$

Usando a função de probabilidade, tem-se


$$\begin{aligned} p(0, 2, 2) &= \frac{4!}{0! \cdot 2! \cdot 2!} \cdot 0.2^0 \cdot 0.3^2 \cdot 0.5^2 \\ &= 0.135 \end{aligned}$$

# Diferença entre Multinomial e Binomiais



## Multinomial

Qual seu chocolate favorito?


Ao leite



Meio amargo




Branco





## Binomiais

Qual chocolate o cliente comprou?

Ao leite



Meio amargo



Branco



Ícone retirado do <https://www.flaticon.com/authors/photo3idea-studio>



# A distribuição Normal Multivariada

# Características de um v.a. Normal Multivariada

- ▶ Um conjunto de variáveis contínuas não limitadas.
- ▶ Individualmente as variáveis são Normais, portanto simétricas.
- ▶ Variáveis apresentam relação linear entre si.
- ▶ Resultam da combinação de muitos fatores de pequena contribuição.
  - ▶ Características genéticas e morfológicas.
  - ▶ Traços latentes.
  - ▶ Índices econômicos.




Figura 3. Diagramas de dispersão para 4 variáveis contínuas.

# Exemplos de v.a. com distribuição Normal Multivariada

- ▶ Peso de massa seca, altura de planta e altura da primeira espiga em uma planta de milho.
- ▶ Peso, comprimento e circunferência de uma banana.
- ▶ Comprimentos no crânio de um fóssil ou animal.
- ▶ Variação de um conjunto de índices econômicos ou mercadorias: e.g. combustível.
- ▶ Traço latente para resolução de problemas de física, matemática, química, etc.

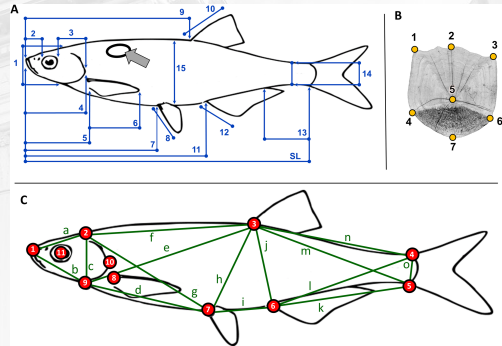


Figura 4. Distâncias medidas em um peixe para estudo morfométrico. Fonte: <https://cutt.ly/AhlsOWo>.

# Importância da Normal Multivariada

- ▶ Modelar a estrutura de correlação ou dependência.
  - ▶ Modelos de séries temporais: correlação entre datas.
  - ▶ Modelos geoestatísticos: correlação entre pontos no espaço.
  - ▶ Modelos genéticos: correlação entre características.
- ▶ Técnicas de análise multivariada.
  - ▶ Análise de discriminante linear.
  - ▶ Análise fatorial exploratória e confirmatória.
  - ▶ Análise de correlação canônica.
  - ▶ Análise de variância multivariada.

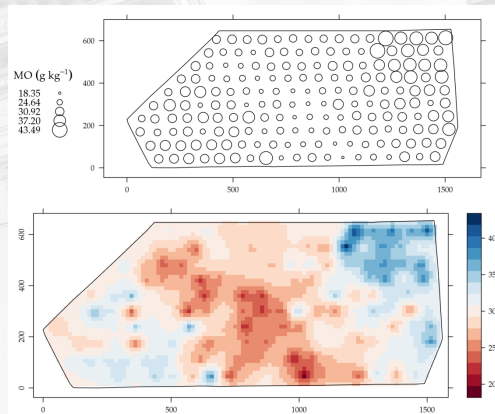


Figura 5. Gráfico de valores observados de matéria orgânica do solo e o mapa com a predição para todo o terreno.

# A distribuição Normal Multivariada

Um vetor aleatório contínuo  $\mathbf{Y}$  ( $p \times 1$ ) tem distribuição Normal multivariada se sua densidade conjunta é dada por

$$f(\mathbf{y}) = \left( \frac{1}{2\pi} \right)^{p/2} \det(\Sigma)^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{y} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{y} - \boldsymbol{\mu}) \right\},$$

em que

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_p \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_p \end{bmatrix} \quad \text{e} \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \dots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \dots & \sigma_p^2 \end{bmatrix}.$$

Denotamos por  $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \Sigma)$ .

A média e variância do vetor aleatório são dados por

$$E(\mathbf{Y}) = \boldsymbol{\mu} \quad \text{e} \quad V(\mathbf{Y}) = \Sigma.$$

# Distribuições marginais e condicionais (caso bivariado)

**Distribuição marginal:** A distribuição marginal de cada elemento de um vetor aleatório Normal é também Normal. Isto é,

$$Y_i \sim N(\mu_i, \sigma_i^2) \quad i \in \{1, 2\}.$$

**Distribuição condicional:** A distribuição condicional de cada elemento de um vetor aleatório em relação ao outro também é Normal. Isto é,

$$Y_i | Y_j = y_j \sim N(\mu_{i|j}, \sigma_{i|j}^2), \quad i \neq j \in \{1, 2\},$$

em que

$$\mu_{i|j} = \mu_i + \frac{\sigma_{ij}}{\sigma_j^2}(y_j - \mu_j) \quad \text{e} \quad \sigma_{i|j}^2 = \sigma_i^2 - \frac{\sigma_{ij} \cdot \sigma_{ji}}{\sigma_j^2}.$$



# Exemplo: altura de mães e filhas

A altura de mães e filhas adultas segue distribuição Normal bivariada com parâmetros

$$\mu = \begin{bmatrix} 165 \\ 165 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 49 & 35 \\ 35 & 49 \end{bmatrix}.$$

- ▶ Dado que uma mãe tem 172 cm de altura, qual a estatura esperada para a filha quando adulta?
- ▶ Qual a probabilidade da filha ter mais de 180 cm?



Figura 6. Mãe com sua filha. Foto de [Pixabay](#) no Pexels.

# Solução

- ▶ A altura esperada para a filha é

$$\begin{aligned}\mu_{f|m} &= \mu_f + \frac{\sigma_{fm}}{\sigma_m^2}(y_m - \mu_m) \\ &= 165 + \frac{35}{49}(172 - 165) = 170.\end{aligned}$$

- ▶ A variância de  $Y_f|Y_m = 172$  é

$$\begin{aligned}\sigma_{f|m}^2 &= \sigma_f^2 - \frac{\sigma_{fm} \cdot \sigma_{mf}}{\sigma_m^2} \\ &= 49 - \frac{35 \cdot 35}{49} = 47.57.\end{aligned}$$

- ▶ E assim,  $P(Y_f > 180|Y_m = 172) = 0.074$ .




Figura 7. Distribuição Normal bivariada para o problema da altura de mães e filhas.




Figura 8. Distribuição Normal bivariada para o problema da altura de mães e filhas.

# Distribuições marginais e condicionais (caso geral)

Considere a partição do vetor aleatório  $Y$  em dois subvetores complementares de tamanho  $p$  e  $q$ . Ou seja,

$$Y = \begin{bmatrix} Y_p \\ Y_q \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_p \\ \mu_q \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{pp} & \Sigma_{pq} \\ \Sigma_{qp} & \Sigma_{qq} \end{bmatrix}.$$

**Distribuição marginal:** A distribuição marginal de  $Y_p$  é Normal. Isto é,

$$Y_p \sim N_p(\mu_p, \Sigma_{pp}).$$

**Distribuição condicional:** A distribuição condicional de  $Y_p$  em relação à  $Y_q$  é Normal. Isto é,

$$Y_p | Y_q = y_q \sim N_p(\mu_{p|q}, \Sigma_{p|q}), \quad \text{em que}$$

$$\mu_{p|q} = \mu_p + \Sigma_{pq} \Sigma_{qq}^{-1} (y_q - \mu_q) \quad \text{e} \quad \Sigma_{p|q} = \Sigma_{pp} - \Sigma_{pq} \Sigma_{qq}^{-1} \Sigma_{qp}.$$

# Algumas propriedades

- ▶ Correlação 0 (zero) implica em **independência**.
- ▶ Variáveis individualmente apresentarem distribuição Normal não implica em distribuição Normal conjunta.

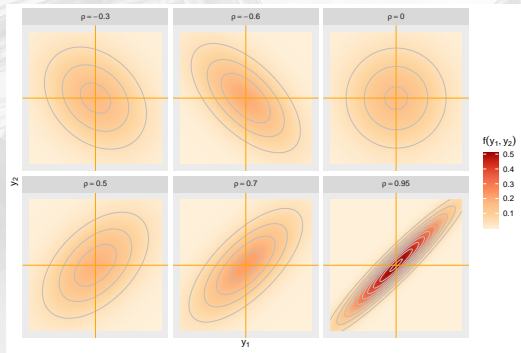


Figura 9. Gráficos da densidade da Normal bivariada com diferentes valores para a correlação.



# Teoremas limites

# Motivação

- ▶ Sejam  $Y_1, Y_2, \dots, Y_n$  variáveis aleatórias (v.a) independentes e idênticamente distribuídas (iid) com  $E(Y_i) = \mu$  e  $V(Y_i) = \sigma^2$ .
- ▶ Objetivo: Baseado em um conjunto de realizações de  $Y_i$  *estimar* o valor  $\mu$ .
- ▶ Estratégia simples: Usar a versão empírica de  $\mu$ , i.e.

$$\hat{\mu} = \sum_{i=1}^n \frac{Y_i}{n}.$$

- ▶  $\hat{\mu}$  é uma variável aleatória?
- ▶ Qual a esperança de  $\hat{\mu}$ ?
- ▶ Qual a variância de  $\hat{\mu}$ ?
- ▶ Qual é a distribuição de probabilidade de  $\hat{\mu}$ ?

# Sequência de v.a's

- **Definição (Sequência de v.a's):** Sejam  $X_1, X_2, \dots, X_n$  v.a's com função de probabilidade (fp) ou função densidade de probabilidade (fdp)  $f(X, \theta)$ . Para uma função  $g(\cdot)$  define-se uma sequência de v.a's como,

$$\begin{aligned}Y_1 &= g(X_1) \\Y_2 &= g(X_1, X_2) \\&\vdots \\Y_n &= g(X_1, \dots, X_n).\end{aligned}$$

- Estatísticas amostrais são funções do tamanho da amostra e podem ser tratadas como sequência de v.a's.
- Exemplos: Média e variância amostral.



# Convergência em probabilidade

- **Convergência em probabilidade:** Seja  $Y_1, \dots, Y_n$  uma sequência de v.a.'s. Dizemos que  $Y_n$  converge em probabilidade para uma constante ou v.a  $Y$ , se  $\forall \epsilon > 0$ , tem-se

$$\lim_{n \rightarrow \infty} P(|Y_n - Y| > \epsilon) = 0.$$

- Notação:  $Y_n \xrightarrow{P} Y$ .

- Observações:

1.  $Y_n \xrightarrow{P} Y$  é equivalente a  $(Y_n - Y) \xrightarrow{P} 0$ .
2. Para vetores aleatórios, tem-se

$$Y_n = (Y_{n1}, \dots, Y_{nk})^T, Y_n \xrightarrow{P} Y \quad \text{se}$$

$$Y_{ni} \xrightarrow{P} Y_i \quad \text{para } i = 1, \dots, n.$$



# Desigualdades

# Desigualdades

- ▶ **Markov:** Seja  $Y$  uma v.a não negativa com  $E(Y) = \mu$  e  $\epsilon > 0$ . Então,

$$P(Y \geq \epsilon) \leq \frac{E(Y)}{\epsilon}.$$

- ▶ Demonstração.
- ▶ Chebyshev: Seja  $Y$  qualquer v.a com  $E(Y) = \mu$  e  $V(Y) = \sigma^2$  ambos finitos. Então, para todo  $\epsilon > 0$

$$P(|Y - \mu| > \epsilon) \leq \frac{V(Y)}{\epsilon^2} = \frac{\sigma^2}{\epsilon^2}.$$

- ▶ Demonstração.
- ▶ Corolário: Seja  $\psi(\cdot)$  uma função monotônica, então

$$P(\psi(|Y|) > \psi(\epsilon)) \leq \frac{E(\psi(Y))}{\psi(\epsilon)}.$$



# **Leis dos grandes números**

# Lei dos Grandes Números: Chebyshev

- **Teorema:** Seja  $Y_1, \dots, Y_n$  v.a. iid com  $E(Y_i) = \mu$  e  $V(Y_i) = \sigma^2$  ambos finitos. Então,

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{P} E(Y_i) = \mu.$$

- Demonstração.
- Ilustração computacional.

# Lei dos Grandes Números: Kolmogorov

- **Teorema:** Seja  $Y_1, \dots, Y_n$  v.a. iid com  $E(|Y_i|) < \infty$  e  $E(Y_i) = \mu$ . Então,

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{P} E(Y_i) = \mu.$$

- Condição  $E(|Y_i|) < \infty$  significa que  $E(|Y_i|) = \int |y_i| f(y_i, \theta) dy_i < \infty$ .
- Controla as caudas da distribuição.
- Caudas não podem ser muito pesadas, tal que  $E(|Y_i|) = \infty$ , mas ainda podem ser pesadas a ponto de  $E(Y_i^2) = \infty$ .
- Kolmogorov não requer que  $V(Y_i)$  exista.
- Kolmogorov cobre distribuições com caudas pesadas como a t-Student.
- Demonstração é trabalhosa em sua forma geral.
- Ilustração computacional.

# Manipulação de limites e convergência em probabilidade

- ▶ **Teorema de Slutsky:** Sejam  $Y_n$  e  $Z_n$  sequências de v.a's e sejam  $b, c$  e  $d$  constantes.
  - ▶ Se  $Y_n \xrightarrow{P} c$  então  $bY_n \xrightarrow{P} bc$ .
  - ▶ Se  $Y_n \xrightarrow{P} c$  e  $Z_n \xrightarrow{P} d$  então  $Y_n + Z_n \xrightarrow{P} c + d$ .
  - ▶ Se  $Y_n \xrightarrow{P} c$  e  $Z_n \xrightarrow{P} d$  então  $\frac{Y_n}{Z_n} \xrightarrow{P} \frac{c}{d}$  desde que  $d \neq 0$  e  $Y_n Z_n \xrightarrow{P} cd$ .
  - ▶ Se  $Y_n \xrightarrow{P} c$  e  $h(\cdot)$  é uma função contínua então  $h(Y_n) \xrightarrow{P} h(c)$ .
- ▶ Demonstração (ver Magalhães (2006) Ed.2 pag 319).



# Preliminares: Teorema Central do Limite



# Convergência em distribuição

- ▶ Seja  $Y_1, \dots, Y_n$  uma sequência de v.a. Dizemos que  $Y_n$  converge em distribuição para uma v.a  $Y$  e escrevemos  $Y_n \xrightarrow{D} Y$  se

$$F_{Y_n}(y) = P(Y_n \leq y) \rightarrow F_Y(y) = P(Y \leq y), \quad n \rightarrow \infty.$$

- ▶ Na maioria das aplicações  $Y$  será normal ou qui-quadrado.
- ▶ Convergência em distribuição em geral é demonstrada via Teorema Central do Limite.
- ▶ Se  $n$  é grande usamos a distribuição de  $Y$  como uma aproximação para a distribuição de  $Y_n$ .
- ▶ Distribuição exata de  $Y_n$  em geral é difícil de se obter.

# Função geradora de momentos

- ▶ **Proposição 1:** Se  $X$  e  $Y$  são v.a independentes com fgm  $M_X(t)$  e  $M_Y(t)$ . Seja  $Z = X + Y$ , então  $M_Z(t) = M_X(t)M_Y(t)$ .
- ▶ **Proposição 2:** Se  $X$  é uma v.a com fgm  $M_X(t)$  e  $Y = a + bX$ , então  $M_Y(t) = e^{at}M_X(bt)$ .
- ▶ **Teorema da Continuidade de Levy:** Seja  $F_n$  uma sequência de funções de distribuições acumuladas com correspondentes funções geradoras de momentos  $M_n(t)$ . Seja  $F$  uma cdf com fgm  $M(t)$ . Se  $M_n(t) \rightarrow M(t) \quad \forall t$  em um intervalo aberto contendo zero, então  $F_n(y) \rightarrow F_Y(y) \quad \forall y$ .
- ▶ Função geradora de momentos distribuição normal padrão  $M_Y(t) = e^{t^2/2}$ .
- ▶ Exponencial  $e^x = \lim_{n \rightarrow \infty} [1 + (x/n)]^n$ .

# Séries de Taylor

- Suponha que uma função  $f(x)$  é derivável  $(n + 1)$  vezes em um intervalo contendo  $x = x_0$ .
- Expansão em **Série de Taylor** de  $f(x)$  em torno de  $x = x_0$  consiste em reescrever  $f(x)$  da seguinte forma:

$$f(x) = f(x_0) + (x - x_0) \frac{df(x)}{dx} \Big|_{x=x_0} + \frac{(x - x_0)^2}{2!} \frac{d^2f(x)}{dx^2} \Big|_{x=x_0} + \frac{(x - x_0)^3}{3!} \frac{d^3f(x)}{dx^3} \Big|_{x=x_0} + \dots + \frac{(x - x_0)^n}{n!} \frac{d^nf(x)}{dx^n} \Big|_{x=x_0} + e_n(x)$$

onde o termo  $e_n(x)$  é chamado de resíduo ou erro, e dado por

$$e_n(x) = \frac{(x - x_0)^{n+1}}{(n + 1)!} \frac{d^{n+1}f(x)}{dx^{n+1}} \Big|_{x=\epsilon}$$

sendo  $\epsilon$  um valor entre  $x$  e  $x_0$ .

# Teorema Central do Limite

- **Teorema Lindeberg-Levy:** Seja  $Y_1, \dots, Y_n$  v.a's iid com  $E(Y_i) = \mu$  e  $V(Y_i) = \sigma^2 < \infty$ . Então,

$$\sqrt{n} \left( \frac{\bar{Y} - \mu}{\sigma} \right) \xrightarrow{D} Z \sim N(0,1), \quad \text{para } n \rightarrow \infty.$$

- Isso significa que, para todo  $y \in \mathbb{R}$ ,

$$P(Y_n \leq y) \rightarrow \Phi(y) \quad \text{quando } n \rightarrow \infty,$$

onde

$$\Phi(y) = \int_{-\infty}^y \phi(z) dz \quad \text{e} \quad \phi(z) = \frac{1}{\sqrt{2\pi}} \exp \left( -\frac{1}{2} z^2 \right).$$

- Forma alternativa:  $\bar{Y} \sim N(\mu, \sigma^2/n)$ .

# Teorema Central do Limite (versão multivariada)

- **Teorema Lindeberg-Levy multivariado:** Sejam  $Y_1, \dots, Y_n$  vetores aleatórios  $p$ -dimensionais com  $E(Y_i) = \mu$  e  $V(Y_i) = [(Y_i - \mu)(Y_i - \mu)^T] = \Sigma$ , onde  $\Sigma$  é não-singular. Denote  $\Sigma^{-1} = \Sigma^{-\frac{1}{2}}\Sigma^{-\frac{1}{2}}$ . Então,

$$\sqrt{n}\Sigma^{-\frac{1}{2}}(\bar{Y} - \mu) \xrightarrow{D} Z \sim N(\mathbf{0}, I),$$

onde  $N(\mathbf{0}, I)$  denota uma distribuição normal multivariada com média zero e matriz de covariância identidade,

$$f(z) = (2\pi)^{-p/2} \exp\left(-\frac{1}{2}z^T z\right).$$

- Formas alternativas

$$\sqrt{n}(\bar{Y} - \mu) \sim N(\mathbf{0}, \Sigma)$$

$$\bar{Y} \sim N(\mu, n^{-1}\Sigma).$$

# Teorema Central do Limite

- **Teorema Lindeberg-Feller:** Seja  $Y_1, \dots, Y_n$  v.a independentes  $E(Y_i) = \mu_i$  e  $V(Y_i) = \sigma_i^2 < \infty$ . Defina,  $\bar{\mu}_n = n^{-1} \sum_{i=1}^n \mu_i$  e  $\bar{\sigma}_n^2 = n^{-1} \sum_{i=1}^n \sigma_i^2$ . Suponha que

$$\lim_{n \rightarrow \infty} \max_i \frac{\sigma_i^2}{n \bar{\sigma}_n^2} = 0$$

$$\lim_{n \rightarrow \infty} \bar{\sigma}_n^2 = \bar{\sigma}^2 < \infty.$$

Então

$$\sqrt{n} \left( \frac{\bar{Y} - \bar{\mu}_n}{\bar{\sigma}_n^2} \right) \xrightarrow{D} Z \sim N(0, 1).$$

- De forma equivalente,

$$\sqrt{n}(\bar{Y} - \bar{\mu}_n) \xrightarrow{D} N(0, \bar{\sigma}_n^2).$$

# Teorema Central do Limite

- **Teorema Liapounov:** Sejam  $Y_1, \dots, Y_n$  v.a independentes  $E(Y_i) = \mu_i$  e  $V(Y_i) = \sigma_i^2 < \infty$ . Suponha que

$$E[|Y_i - \mu_i|^{2+\delta}] \leq M < \infty$$

para algum  $\delta > 0$ . Se  $\bar{\sigma}_n^2$  é positiva e finita para todo  $n$  suficientemente grande, então

$$\sqrt{n} \left( \frac{\bar{Y} - \bar{\mu}_n}{\bar{\sigma}_n} \right) \xrightarrow{D} Z \sim N(0, 1).$$

- Equivalentemente,

$$\sqrt{n}(\bar{Y} - \bar{\mu}_n) \xrightarrow{D} N(0, \bar{\sigma}^2).$$

- Liapounov é equivalente a Lindeberg-Feller só que mais simples de entender e verificar na prática.

# Resultados para manipular TCL's

- ▶ **Teorema Slutsky:** Sejam  $Y_n$  e  $Z_n$  sequência de v.a tais que  $Y_n \xrightarrow{D} Y$  e  $Z_n \xrightarrow{P} c$ , onde  $Y$  é uma v.a e  $c$  é uma constante. Então, os seguintes resultados valem quando  $n \rightarrow \infty$ :
  - ▶  $Z_n Y_n \xrightarrow{D} cY$ .
  - ▶  $\frac{Y_n}{Z_n} \xrightarrow{D} \frac{Y}{c}$  desde que  $c \neq 0$ .
  - ▶  $Y_n + Z_n \xrightarrow{D} Y + c$ .



# Exercício

1. Seja  $Y_1, \dots, Y_n$  v.a iid com  $E(Y_i) = \mu$  e  $V(Y_i) = \sigma^2 < \infty$ .
  - a) Mostre que  $\bar{\sigma}^2 \xrightarrow{P} \sigma^2$  onde  $\bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \mu)^2$ .
  - b) Obtenha a distribuição aproximada de  $\bar{\sigma}^2$ .
  - c) Faça uma ilustração computacional da distribuição aproximada conforme o tamanho da amostra cresce. Use  $n = 50, 250$  e  $1000$ .
  - d) Compare computacionalmente a distribuição aproximada com a distribuição exata apresentada na semana 3.