

PROBABILIDADE E ESTATÍSTICA MATEMÁTICA I



ARA, A.

ara@ufpr.br

Slide 03

DISTRIBUIÇÕES CONDICIONAIS E INDEPENDÊNCIA

DISTRIBUIÇÕES CONDICIONAIS

Anteriormente foram vistas algumas distribuições de probabilidade conjunta para várias variáveis aleatórias (vetor aleatório).

Nesta aula, vamos introduzir as distribuições marginais, condicionais e independência.

DISTRIBUIÇÕES MARGINAIS

Funções de densidade de probabilidade marginal se \mathbf{X} e \mathbf{Y} são conjuntamente variáveis aleatórias contínuas, então $f_{\mathbf{X}}(\cdot)$ e $f_{\mathbf{Y}}(\cdot)$ são chamadas de funções de densidade de probabilidade marginal.

De maneira geral, seja $\mathbf{X}_i, \dots, \mathbf{X}_{im}$ qualquer subconjunto das variáveis aleatórias contínuas conjuntamente $\mathbf{X}_1, \dots, \mathbf{X}_k$, $f_{\mathbf{X}_i, \dots, \mathbf{X}_{im}}(\mathbf{x}_i, \dots, \mathbf{x}_{im})$ é chamada de densidade marginal da variável aleatória \mathbf{m} -dimensional $(\mathbf{X}_i, \dots, \mathbf{X}_{im})$

$$f_{\mathbf{X}}(\mathbf{x}) = \int f_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y}) d\mathbf{y} \text{ e } f_{\mathbf{Y}}(\mathbf{y}) = \int f_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y}) d\mathbf{x}$$

Analogamente,

$$P(\mathbf{X} = \mathbf{x}) = \sum_{\mathbf{y}} P(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y}) \text{ e } P(\mathbf{Y} = \mathbf{y}) = \sum_{\mathbf{x}} P(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y})$$

DISTRIBUIÇÕES CONDICIONAIS

Função de densidade condicional discreta

Sejam \mathbf{X} e \mathbf{Y} variáveis aleatórias conjuntamente discretas com função de probabilidade discreta conjunta $\mathbf{P}(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y})$, a função de probabilidade condicional de \mathbf{Y} dado $\mathbf{X} = \mathbf{x}$, denotada por

$$f_{\mathbf{Y}|\mathbf{X}}(\mathbf{y}|\mathbf{x}) = \frac{\mathbf{P}(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y})}{\mathbf{P}(\mathbf{X} = \mathbf{x})}$$

A função de probabilidade condicional de \mathbf{Y} dado $\mathbf{X} = \mathbf{x}$, denotada por

$$f_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}|\mathbf{y}) = \frac{\mathbf{P}(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y})}{\mathbf{P}(\mathbf{Y} = \mathbf{y})}$$

DISTRIBUIÇÕES CONDICIONAIS

Função de distribuição acumulada condicional discreta

Sejam \mathbf{X} e \mathbf{Y} variáveis aleatórias conjuntamente discretas com função de probabilidade discreta conjunta $\mathbf{P}(\mathbf{X} = \mathbf{x}, \mathbf{Y} = \mathbf{y})$, a função de distribuição acumulada condicional discreta de \mathbf{Y} dado $\mathbf{X} = \mathbf{x}$, denotada por

$$F_{\mathbf{Y}|\mathbf{X}}(\mathbf{y}|\mathbf{x}) = \sum_{\{j:\mathbf{y}_j \leq \mathbf{y}\}} f_{\mathbf{Y}|\mathbf{X}}(\mathbf{y}_j|\mathbf{x})$$

Analogamente,

$$F_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}|\mathbf{y}) = \sum_{\{j:\mathbf{x}_j \leq \mathbf{x}\}} f_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}_j|\mathbf{y})$$

DISTRIBUIÇÕES CONDICIONAIS

Função de densidade condicional contínua

Sejam \mathbf{X} e \mathbf{Y} variáveis aleatórias contínuas distribuídas conjuntamente com função densidade de probabilidade conjunta $\mathbf{f}(\mathbf{x}, \mathbf{y})$, a função de densidade probabilidade condicional de \mathbf{Y} dado $\mathbf{X} = \mathbf{x}$, denotada por

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f(x)}$$

A função de probabilidade condicional de \mathbf{X} dado $\mathbf{Y} = \mathbf{y}$, denotada por

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f(y)}$$

DISTRIBUIÇÕES CONDICIONAIS

Função de distribuição acumulada condicional contínua

Sejam \mathbf{X} e \mathbf{Y} variáveis aleatórias contínuas distribuídas conjuntamente com função densidade de probabilidade conjunta $\mathbf{f}(\mathbf{x}, \mathbf{y})$, a função de distribuição acumulada condicional de \mathbf{Y} dado $\mathbf{X} = \mathbf{x}$, denotada por

$$F_{Y|X}(y|x) = \int_{-\infty}^y f_{Y|X}(y|x)dy$$

Analogamente,

$$F_{X|Y}(x|y) = \int_{-\infty}^x f_{X|Y}(x|y)dx$$

DISTRIBUIÇÕES CONDICIONAIS

Exemplo: Sejam X_1, \dots, X_5 variáveis aleatórias conjuntamente distribuídas. Seja $W = (X_1, X_2)$ e $V = (X_3, X_5)$

$$f_{W|V}(w, v) = f_{X_1, X_2|X_3, X_5}(x_1, x_2|x_3, x_5) = \frac{f_{X_1, X_2, X_3, X_5}(x_1, x_2, x_3, x_5)}{f_{X_3, X_5}(x_3, x_5)}$$

DISTRIBUIÇÕES CONDICIONAIS

Se X é uma v.a. discreta e Y é qualquer variável aleatória, então $F_{Y|X}(y|x)$ pode ser definida como $P(Y \leq y|X = x)$ com x é um ponto de massa de probabilidade de X .

Se X é uma v.a. contínua, para qualquer evento A , $P(A|X = x)$ não pode ser definido pois $P(X = x|0)$.

Entretanto, se x é tal que os eventos $\{x - h < X < x + h\}$ tem probabilidade positiva para cada $h > 0$, então $P(A|X = x)$ poderia ser definido como

$$P(A|X = x) = \lim_{0 < h \rightarrow 0} P[A|x - h < X < x + h]$$

desde que o limite exista.

INDEPENDÊNCIA

Independência estocástica: Seja (X_1, \dots, X_k) uma variável aleatória k -dimensional, (X_1, \dots, X_k) são definidos para serem estocasticamente independentes se e somente se

$$F_{X_1, \dots, X_k}(x_1, \dots, x_k) = \prod_{i=1}^k F_{X_i}(x_i)$$

para todos os x_1, \dots, x_k .

Da mesma forma,

$$f_{X_1, \dots, X_k}(x_1, \dots, x_k) = \prod_{i=1}^k f_{X_i}(x_i)$$

OBS: Para X e Y independentes, temos que $f_{X,Y}(x, y) = f_X(x)f_Y(y)$, implica que $f_{X|Y}(x|y) = f_X(x)$ e $f_{Y|X}(y|x) = f_Y(y)$.

ESPERANÇA

Seja (X_1, \dots, X_k) uma variável aleatória k -dimensional com densidade $f_{X_1, \dots, X_k}(\cdot, \dots, \cdot)$, o valor esperado de uma função $g(\cdot, \dots, \cdot)$ da variável aleatória k -dimensional é denotado por $E[g(X_1, \dots, X_k)]$, sendo

- para v. a. k -dimensional discreta:

$$E[g(X_1, \dots, X_k)] = \sum_{x_1} \dots \sum_{x_k} g(x_1, \dots, x_k) f_{X_1, \dots, X_k}(x_1, \dots, x_k)$$

- para v. a. k -dimensional contínua:

$$E[g(X_1, \dots, X_k)] = \int \dots \int g(x_1, \dots, x_k) f_{X_1, \dots, X_k}(x_1, \dots, x_k) dx_1 \dots dx_k$$

ESPERANÇA

Teorema: Se $g(x_1, \dots, x_k) = x_i$ então

$$E[g(x_1, \dots, x_k)] = E[X_i] = E(X_i) = \mu_{X_i}$$

Denotamos por $\mu_X = (\mu_{X_1}, \dots, \mu_{X_k})$ o vetor de médias da variável aleatória \mathbf{k} -dimensional (vetor aleatório) $\mathbf{X} = (X_1, \dots, X_k)$.

ESPERANÇA

Teorema: Se $g(x_1, \dots, x_k) = (x_i - E(X_i))^2$ então

$$E[g(x_1, \dots, x_k)] = E[(x_i - E(X_i))^2] = \text{Var}(X_i)$$

ESPERANÇA

Exemplo: Suponha $f_{X,Y}(x, y) = (x + y)I_{(0,1)}(x)I_{(0,1)}(y)$

$$E[XY] = \int_0^1 \int_0^1 xy(x + y)dx dy = \frac{1}{3}.$$

$$E[X + Y] = \int_0^1 \int_0^1 (x + y)(x + y)dx dy = \frac{7}{6}.$$

$$E[X] = E[Y] = \frac{7}{12}.$$

ESPERANÇA

Covariância: Seja X e Y duas variáveis aleatórias definidas no mesmo espaço de probabilidade. A covariância de X e Y é definida como

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

desde que a esperança exista.

Resultado: $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$

ESPERANÇA

Coeficiente de Correlação: O Coeficiente de Correlação de X e Y é definido como

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

desde que a covariância exista, $\sigma_X > 0$ e $\sigma_Y > 0$.

A covariância e o coeficiente de correlação das variáveis aleatórias X e Y são medidas de uma relação linear de X e Y .

ESPERANÇA

Teorema: Se X e Y são v.a. independentes e $g_1(\cdot)$ e $g_2(\cdot)$ duas funções, então

$$E[g_1(X)g_2(Y)] = E[g_1(X)]E[g_2(Y)]$$

Resultado: Se X e Y são v.a. independentes, então $\text{Cov}[X, Y] = 0$.

ESPERANÇA

Teorema: Se X e Y são v.a

$$E[g(Y)] = E[E[g(Y)|X]]$$

Particularmente,

$$E[Y] = E[E[Y|X]]$$

Variância condicional: A Variância de Y dado $X = x$ é definida por

$$\text{Var}[Y|X = x] = E[Y^2|X = x] - (E[Y|X = x])^2$$

ESPERANÇA

Teorema: $\text{Var}[Y] = E[\text{Var}[Y|X]] + \text{Var}[E[Y|X]]$

Prova:

$$\begin{aligned}
 E[\text{Var}[Y|X]] &= E[E[Y^2|X] - E[(E[Y|X])^2]] \\
 &= E[Y^2] - (E[Y])^2 - E[(E[Y|X])^2] + (E[Y])^2 \\
 &= \text{Var}[Y] - E[(E[Y|X])^2] + (E[E[Y|X]])^2 \\
 &= \text{Var}[Y] - \text{Var}[E[Y|X]]
 \end{aligned}$$

Teorema da Desigualdade de Cauchy-Schwarz: Sejam X e Y com segundos momentos finitos; então $E[XY]^2 \leq E[X^2]E[Y^2]$, com igualdade se e somente se $P[Y = cX] = 1$ para alguma constante c .

Assim, temos que $|\rho_{X,Y}| \leq 1$, com igualdade se e somente se uma variável aleatória é função linear da outra com probabilidade 1.

Teorema: Para as variáveis aleatórias X_1, \dots, X_n

$$E \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n E[X_i]$$

e

$$\text{var} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \text{var}[X_i] + 2 \sum_{i < j} \text{cov}[X_i, X_j]$$

OBS: se as variáveis são não correlacionadas, temos que: $\text{var} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \text{var}[X_i]$

Particularmente: **Teorema do Limite Central**

Se X_1, \dots, X_n são variáveis aleatórias independentes e identicamente distribuídas com média μ_X e variância σ_X^2 , então

$$E(\bar{X}_n) = \mu_X \quad \text{e} \quad \text{Var}(\bar{X}_n) = \frac{\sigma_X^2}{n}$$

com $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$.

A SHORT REVIEW:

- Funções de dist. condicional para variáveis aleatórias discretas
- Funções de dist. condicional para variáveis aleatórias contínuas
- Comentários sobre funções de distribuição condicional
- Independência
- Esperança