

# Probabilidade e Estatística Matemática I

## Parte 2: Variáveis Aleatórias, Funções de Distribuição e Esperanças

Silva, J.L.P.

Junho de 2022

# Variáveis aleatórias e função de distribuição acumulada

## Variável aleatória: definição

**Definição** para um dado espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ , uma *variável aleatória* (*va*), denotada por  $X$  ou  $X(\cdot)$  é uma função com domínio  $\Omega$  e contradomínio a reta real. A função  $X(\cdot)$  deve ser tal que o conjunto  $A_r$ , definido por  $A_r = \{\omega : X(\omega) \leq r\}$ , pertence a  $\mathcal{A}$  para todo número real  $r$ .

- Uma *va* é, portanto, uma função do espaço amostral  $\Omega$  nos reais, para a qual é possível calcular a probabilidade de ocorrência de seus valores.
- Apenas os elementos da  $\sigma$ -álgebra  $\mathcal{A}$  têm atribuição de probabilidade.
- Em linguagem matemática mais formal, dizemos que uma v.a. é qualquer função real mensurável em  $\mathcal{A}$ .

## Variável aleatória: exemplo

**Exemplo** Considere o experimento de lançar uma moeda. Seja a va  $X$  o número de caras.  $\Omega = \{\text{cara}, \text{coroa}\}$ , e  $X(\omega) = 1$  se  $\omega = \text{cara}$ , e  $X(\omega) = 0$ , se  $\omega = \text{coroa}$ . Assim, a va  $X$  associa um número real a cada resultado do experimento.

Para verificar que  $X$  é uma va devemos mostrar que ela satisfaz a definição. Ou seja, devemos mostrar que  $\{\omega : X(\omega) \leq r\}$  pertence a  $\mathcal{A}$  para todo número real  $r$ . Seja  $\mathcal{A} = \{\phi, \{\text{cara}\}, \{\text{coroa}\}, \Omega\}$ .

- Se  $r < 0$ ,  $\{\omega : X(\omega) \leq r\} = \phi$ .
- Se  $0 \leq r < 1$ ,  $\{\omega : X(\omega) \leq r\} = \{\text{coroa}\}$ .
- Se  $r \geq 1$ ,  $\{\omega : X(\omega) \leq r\} = \Omega = \{\text{cara}, \text{coroa}\}$ .

Logo, para todo  $r$  o conjunto  $\{\omega : X(\omega) \leq r\}$  pertence a  $\mathcal{A}$ ; portanto,  $X(\cdot)$  é uma va.

## Função de distribuição acumulada: definição

**Definição** A *função de distribuição acumulada* (*fda*) de uma v.a.  $X$ , denotada por  $F_X(\cdot)$ , é definida como a função com domínio na reta real e contradomínio no intervalo  $[0, 1]$  que satisfaz

$$F_X(x) = P(X \leq x) = P(\{\omega : X(\omega) \leq x\}) \text{ para todo número real } x.$$

- Uma *fda* é definida de forma única para cada *va* e pode ser usada para calcular probabilidades de eventos definidos em termos de sua correspondente *va*.
- Diferentes *va*'s podem ter a mesma função de distribuição.

## Função de distribuição acumulada: exemplo

**Exemplo** Considere o experimento de lançar uma moeda. Assuma que a moeda é honesta. Seja  $X$  o número de caras. Então,

$$F_X(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1/2 & \text{se } 0 \leq x < 1 \\ 1 & \text{se } x \geq 1. \end{cases}$$

Ou  $F_X(x) = \frac{1}{2}I_{[0,1)}(x) + I_{[1,\infty)}(x)$ , em  $I_A(\omega)$  é a *função indicadora* de  $A$ , que vale 1 se  $\omega \in A$  e 0 se  $\omega \notin A$ .

## Função de distribuição acumulada: exemplo

**Exemplo** Considere o experimento de lançar dois dados honestos. Seja  $X_k$  o valor da face superior no  $k$ -ésimo lançamento para  $k = 1, 2$ . Note que  $X_1$  e  $X_2$  são duas *va's* diferentes com a mesma *fda*, que vale  $F_{X_k}(x) = \sum_{i=1}^5 \frac{i}{6} I_{[i, i+1)}(x) + I_{[6, \infty)}(x)$ .




Figura 1: Fonte: Mood et. al (1974)

# Função de distribuição acumulada: propriedades

- (i)  $F_X(-\infty) \equiv \lim_{x \rightarrow -\infty} F_X(x) = 0$  e  $F_X(+\infty) \equiv \lim_{x \rightarrow +\infty} F_X(x) = 1$ .
- (ii)  $F_X(\cdot)$  é monótona não-decrescente; isto é,  $F_X(a) \leq F_X(b)$  para  $a < b$ .
- (iii)  $F_X(\cdot)$  é contínua à direita; isto é,

$$\lim_{0 < h \rightarrow 0} F_X(x + h) = F_X(x).$$

Qualquer função  $F(\cdot)$  com domínio na reta real e contradomínio no intervalo  $[0, 1]$  satisfazendo as três propriedades acima é definida como uma *função de distribuição acumulada*.



# Funções de densidade

# Variáveis aleatórias discretas: definição

**Definição** Uma  $va$   $X$  será definida como *discreta* se assume um número enumerável de valores (finito ou infinito).

- Assim, existe um número finito ou infinito enumerável de valores reais  $x_1, x_2, x_3, \dots$  que  $X$  pode assumir.
- Se  $X$  é discreta com valores distintos  $x_1, x_2, \dots, x_n, \dots$ , então  $\Omega = \bigcup_n \{\omega : X(\omega) = x_n\} = \bigcup_n \{X = x_n\}$ , e  $\{X = x_i\} \cap \{X = x_j\} = \emptyset$  para  $i \neq j$ ; logo  $1 = P(\Omega) = \sum_n P(X = x_n)$  pelo terceiro axioma da probabilidade.

# Função densidade discreta: definição

**Definição** Se  $X$  é discreta com valores  $x_1, x_2, \dots, x_n, \dots$ , então a função, denotada por  $f_X(\cdot)$  e definida por

$$f_X(x) = \begin{cases} P(X = x_j) & \text{se } x = x_j, j = 1, 2, \dots, n, \dots \\ 0 & \text{se } x \neq x_j. \end{cases}$$

é chamada *função de densidade discreta* de  $X$ .

- Os valores da  $va$  discreta são chamados *pontos de massa* e  $f_X(x_i)$  denota a massa associada com o ponto de massa  $x_i$ . A notação  $p_X(\cdot)$  também é usada.
- $f_X(\cdot)$  é uma função com domínio na reta real e contradomínio  $[0, 1]$ .
- Podemos usar a notação  $f_X(x) = \sum_{n=1}^{\infty} P(X = x_n) I_{\{x_n\}}(x)$ , em que  $I_{\{x_n\}}(x) = 1$  se  $x = x_n$  e 0 se  $x \neq x_n$ .

# Função densidade discreta: teorema

**Teorema** Seja  $X$  uma va discreta.  $F_X(\cdot)$  pode ser obtida de  $f_X(\cdot)$  e vice-versa.

**Prova** Denote os pontos de massa de  $X$  por  $x_1, x_2, \dots$

(ida) Suponha  $f_X(\cdot)$  dada; então  $F_X(x) = \sum_{\{j: x_j \leq x\}} f_X(x_j)$ .

(volta) Por outro lado, suponha que  $F_X(\cdot)$  é dada; então  $f_X(x_j) = F_X(x_j) - \lim_{0 < h \rightarrow 0} F_X(x_j - h)$ ; portanto,  $f_X(x_j)$  pode ser encontrada para cada ponto de massa  $x_j$ . Como  $f_X(x) = 0$  para  $x \neq x_j$ ,  $j = 1, 2, \dots$ , então  $f_X(x)$  é determinada para todos os números reais.

## Função densidade discreta: definição

**Definição** Qualquer função  $f(\cdot)$  com domínio na reta real e contradomínio  $[0, 1]$  é definida como uma *função de densidade discreta* se, para algum conjunto enumerável,  $x_1, x_2, \dots, x_n, \dots$

- ❶  $f(x_j) > 0$  para  $j = 1, 2, \dots$
- ❷  $f(x) = 0$  para  $x \neq x_j, j = 1, 2, \dots$
- ❸  $\sum f(x_j) = 1$ , em que o somatório se dá sobre os pontos  $x_1, x_2, \dots, x_n, \dots$

- A definição permite falar de funções de densidade discretas sem alusão a variáveis aleatórias.
- Assim, podemos nos referir a propriedades que uma função de densidade deve ter sem nos referirmos a uma variável aleatória.

# Variáveis aleatórias contínuas: definição

**Definição** A *va*  $X$  é chamada *contínua* se existe uma função  $f_X(\cdot)$  tal que  $F_X(x) = \int_{-\infty}^x f_X(u)du$  para cada número real  $u$ . A função de distribuição acumulada  $F_X(\cdot)$  de uma *va* contínua  $X$  é chamada *absolutamente contínua*.

**Definição** Se  $X$  é uma *va* contínua, a função  $f_X(\cdot)$  em  $F_X(x) = \int_{-\infty}^x f_X(u)du$  é chamada de *função densidade de probabilidade* de  $X$ .

# Variáveis aleatórias contínuas: teorema

**Teorema** Seja  $X$  uma va contínua. Então  $F_X(\cdot)$  pode ser obtida de  $f_X(\cdot)$  e vice-versa.

**Prova** (*ida*) Se  $X$  é uma va contínua e uma  $f_X(\cdot)$  é dada, então  $F_X(x)$  é obtida integrando  $f_X(\cdot)$ ; isto é,  $F_X(x) = \int_{-\infty}^x f_X(u)du$ . (*volta*) Por outro lado, se  $F_X(\cdot)$  é dada, então uma  $f_X(x)$  pode ser obtida por derivação; isto é,  $f_X(x) = dF_X(x)/dx$  para todos os pontos  $x$  em que  $F_X(x)$  é diferenciável.

- Note que para uma va discreta,  $f_X(x) = P(X = x)$ .
- Para va contínua

$$f_X(x) = \frac{dF_X(x)}{dx} = \lim_{\Delta x \rightarrow 0} \frac{F_X(x + \Delta x) - F_X(x - \Delta x)}{2\Delta x};$$

e, assim,  $f_X(x)2\Delta x \approx F_X(x + \Delta x) - F_X(x - \Delta x) = P(x - \Delta x < X \leq x + \Delta x)$ .

# Variáveis aleatórias contínuas: exemplo

**Exemplo** Seja  $X$  a va que representa a duração de uma chamada telefônica. Podemos assumir que a distribuição de  $X$  é dada por  $F_X(x) = (1 - e^{-\lambda x})I_{[0, \infty)}(x)$  para algum número real  $\lambda$  positivo. A função densidade de probabilidade correspondente é dada por  $f_X(x) = \lambda e^{-\lambda x}I_{[0, \infty)}(x)$ .

Se assumimos que a duração da chamada é medida em minutos, e se  $\lambda = 1/5$ ,

- $P(5 < X \leq 10) = \int_5^{10} \lambda e^{-\lambda x} dx = e^{-5\lambda} - e^{-10\lambda} = e^{-1} - e^{-2} = 0,368 - 0,135 = 0,233$  para  $\lambda = 1/5$ , ou
- $P(5 < X \leq 10) = P(X \leq 10) - P(X \leq 5) = (1 - e^{-10\lambda}) - (1 - e^{-5\lambda}) = e^{-1} - e^{-2} = 0,233$  para  $\lambda = 1/5$ .



# Variáveis aleatórias contínuas: definição

**Definição** Qualquer função  $f(\cdot)$  com domínio na reta real e contradomínio  $[0, \infty)$  é definida como uma *função densidade de probabilidade* se e somente se

❶  $f(x) \geq 0$  para todo  $x$ .

❷  $\int_{-\infty}^{\infty} f(x) dx = 1$ .

- Com esta definição, podemos falar de função densidade de probabilidade sem referência a variáveis aleatórias.

## Outros tipos de variáveis aleatórias

Nem todas as variáveis aleatórias são discretas ou contínuas, e nem todas as funções de distribuição são ou absolutamente contínuas ou discretas.

Vários exemplos práticos envolvem funções de distribuição acumuladas que são parcialmente discretas e parcialmente contínuas.

Há ainda funções de distribuição contínuas, chamadas de *singulares*, cuja derivada é 0 em quase todos os pontos<sup>1</sup>. A classificação como singular tem mais interesse teórico do que prático.

---

<sup>1</sup>“quase todos os pontos” significa que a propriedade só não é válida num conjunto de pontos com probabilidade nula.

## Outros tipos de variáveis aleatórias: exemplo

**Exemplo** Considere o experimento de registrar o tempo que um motorista fica parado em determinada placa de PARE. Seja  $X$  a va que representa o tempo que decorre ao motorista fazer a parada.

- Há uma certa probabilidade de que não haverá tráfego de forma que o motorista prossiga sem precisar parar.
- Por outro lado, se o motorista tem que esperar, a espera pode assumir qualquer valor positivo.

O experimento pode ser modelado assumindo que  $X$  tem uma *fda* dada por  $F_X(x) = (1 - pe^{-\lambda x})I_{[0,\infty)}(x)$ . Esta  $F_X(x)$  tem um salto de  $1 - p$  em  $x = 0$  mas é contínua para  $x > 0$ .

# Outros tipos de variáveis aleatórias: exemplo




Figura 2: Fonte: Mood et. al (1974)

# Decomposição de uma função de distribuição

Qualquer função de distribuição acumulada  $F(x)$  pode ser representada na forma

$$F(x) = p_1 F^d(x) + p_2 F^{ac}(x) + p_3 F^{sc}(x), \quad p_i \geq 0, i = 1, 2, 3,$$

com  $\sum_{i=1}^3 p_i = 1$ . As funções  $F^d(\cdot)$ ,  $F^{ac}(\cdot)$ , e  $F^{sc}(\cdot)$  são as funções de distribuição discreta, absolutamente contínua e singular, respectivamente.

## Decomposição de uma função de distribuição: exemplo

**Exemplo** No exemplo anterior,  $F_X(x) = (1 - pe^{-\lambda x})I_{[0,\infty)}(x)$ . Podemos decompor tal função de distribuição acumulada como

$$F_X(x) = (1 - p)F^d(x) + pF^{ac}(x),$$

em que  $F^d(x) = I_{[0,\infty)}(x)$  e  $F^{ac}(x) = (1 - e^{-\lambda x})I_{[0,\infty)}(x)$ .

Note que

$$\begin{aligned} F_X(x) &= (1 - p)F^d(x) + pF^{ac}(x) \\ &= (1 - p)I_{[0,\infty)}(x) + p(1 - e^{-\lambda x})I_{[0,\infty)}(x) \\ &= (1 - pe^{-\lambda x})I_{[0,\infty)}(x). \end{aligned}$$

# Esperança e momentos

# Média: definição

**Definição** Seja  $X$  uma va. A *média*, ou *esperança*, ou *valor esperado* de  $X$ , denotada por  $\mu_X$  ou  $E(X)$ , é definida por

- (i) Se  $X$  é discreta com pontos de massa  $x_1, x_2, \dots, x_j, \dots$ :

$$E(X) = \sum x_j f_X(x_j).$$

- (ii) Se  $X$  é contínua com função densidade de probabilidade  $f_X(x)$ :

$$E(X) = \int_{-\infty}^{\infty} x f_X(x) dx.$$

- (iii) Para uma va aleatória  $X$  arbitrária:

$$E(X) = \int_0^{\infty} [1 - F_X(x)] dx - \int_{-\infty}^0 F_X(x) dx.$$



## Média: exemplo

**Exemplo** Considere o experimento de lançar dois dados. Seja  $Y$  a diferença absoluta dos valores obtidos. A  $f_Y(y)$  discreta é dada por

$y$	0	1	2	3	4	5
$f_Y(y)$	6/36	10/36	8/36	6/36	4/36	2/36

$$\begin{aligned}
 E(Y) &= \sum y_j f_Y(y_j) = \sum_{i=0}^5 i f_Y(i) \\
 &= 0 \times 6/36 + 1 \times 10/36 + \\
 &\quad 2 \times 8/36 + 3 \times 6/36 + \\
 &\quad 4 \times 4/36 + 5 \times 2/36 \\
 &= 70/36
 \end{aligned}$$

## Média: exemplo

**Exemplo** Seja  $X$  uma va contínua com função de densidade  $f_X(x) = \lambda e^{-\lambda x} I_{[0, \infty)}(x)$ .

$$E(X) = \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = -x e^{-\lambda x} \Big|_0^{\infty} - \int_0^{\infty} (-e^{-\lambda x}) dx = 1/\lambda.$$

A função de distribuição acumulada é  $F_X(x) = (1 - e^{-\lambda x}) I_{[0, \infty)}(x)$ , logo

$$E(X) = \int_0^{\infty} [1 - F_X(x)] dx - \int_{-\infty}^0 F_X(x) dx = \int_0^{\infty} (1 - 1 + e^{-\lambda x}) dx = 1/\lambda.$$

## Média: exemplo

**Exemplo** Seja  $X$  uma *va* contínua com função de densidade  $f_X(x) = x^{-2} I_{[1,\infty)}(x)$ .

$$E(X) = \int_1^{\infty} x \frac{dx}{x^2} = \lim_{b \rightarrow \infty} \log b = \infty.$$

Dizemos que  $E(X)$  não existe. Ou dizemos que a média de  $X$  é infinita já que a integral que define a média resulta em infinito.

## Variância: definição

**Definição** Seja  $X$  uma va e seja  $\mu_X$  sua média. A *variância* de  $X$ , denotada por  $\sigma_X^2$  ou  $Var(X)$ , é definida por:

- (i) Se  $X$  é discreta com pontos de massa  $x_1, x_2, \dots, x_j, \dots$ :

$$Var(X) = \sum_j (x_j - \mu_X)^2 f_X(x_j).$$

- (ii) Se  $X$  é contínua com função densidade de probabilidade  $f_X(x)$ :

$$Var(X) = \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx.$$

- (iii) Para uma va aleatória  $X$  arbitrária:

$$Var(X) = \int_0^{\infty} 2x[1 - F_X(x) + F_X(-x)] dx - \mu_X^2.$$

## Desvio padrão: definição

**Definição** Se  $X$  é uma  $va$ , o desvio padrão de  $X$ , denotado por  $\sigma_X$  é definido como  $+\sqrt{Var(X)}$ .

- O desvio padrão de uma  $va$ , assim como a variância, é uma medida de variabilidade ou dispersão dos seus valores.
- Em muitas aplicações, o desvio padrão é preferível à variância pois está na mesma unidade de medida da própria  $va$ .

## Variância: exemplo

**Exemplo** Seja  $X$  o número total no lançamento de dois dados. Temos que  $\mu_X = 7$  (confira!), logo

$$\begin{aligned}
 \text{Var}(X) &= \sum (x - \mu_X)^2 f_X(x_j) \\
 &= (2 - 7)^2 \times 1/36 + (3 - 7)^2 \times 2/36 + (4 - 7)^2 \times 3/36 + \\
 &\quad (5 - 7)^2 \times 4/36 + (6 - 7)^2 \times 5/36 + (7 - 7)^2 \times 6/36 + \\
 &\quad (8 - 7)^2 \times 5/36 + (9 - 7)^2 \times 4/36 + (10 - 7)^2 \times 3/36 + \\
 &\quad (11 - 7)^2 \times 2/36 + (12 - 7)^2 \times 1/36 \\
 &= 210/36 \approx 5,833.
 \end{aligned}$$

# Média: exemplo

**Exemplo** Seja  $X$  uma va contínua com função de densidade  $f_X(x) = \lambda e^{-\lambda x} I_{[0, \infty)}(x)$ .

$$\begin{aligned} \text{Var}(X) &= \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx \\ &= \int_0^{\infty} \left(x - \frac{1}{\lambda}\right)^2 \lambda e^{-\lambda x} \\ &= 1/\lambda^2. \end{aligned}$$

# Valor esperado de uma função de uma variável aleatória



## Esperança de uma função de *va*: definição

**Definição** Seja  $X$  uma *va* e  $g(\cdot)$  uma função com domínio e contradomínio na reta real. A *esperança* ou *valor esperado*, da função  $g(\cdot)$  da *va*  $X$ , denotada por  $E[g(X)]$  é definida por:

- (i) Se  $X$  é discreta com pontos de massa  $x_1, x_2, \dots, x_j, \dots$ :

$$E[g(X)] = \sum_j g(x_j) f_X(x_j),$$

dado que a série seja absolutamente convergente.

- (ii) Se  $X$  é contínua com função densidade de probabilidade  $f_X(x)$ :

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx,$$

dado que  $\int_{-\infty}^{\infty} |g(x)| f_X(x) dx < \infty$ .

# Propriedades do valor esperado: teorema

## Teorema

- (i)  $E[c] = c$ , para uma constante  $c$ .
- (ii)  $E[cg(X)] = cE[g(X)]$ , para uma constante  $c$ .
- (iii)  $E[c_1g_1(X) + c_2g_2(X)] = c_1E[g_1(X)] + c_2E[g_2(X)]$ .
- (iv)  $E[g_1(X)] \leq E[g_2(X)]$  se  $g_1(X) \leq g_2(X)$ .

# Propriedades do valor esperado: demonstração

**Prova** Assuma  $X$  contínua.

❶ Tome  $g(x) = c$ , então

$$E[g(X)] = E[c] = \int_{-\infty}^{\infty} cf_X(x)dx = c \int_{-\infty}^{\infty} f_X(x)dx = c.$$

❷

$$E[cg(X)] = \int_{-\infty}^{\infty} cg(x)f_X(x)dx = c \int_{-\infty}^{\infty} g(x)f_X(x)dx = cE[g(X)].$$

# Propriedades do valor esperado: demonstração

## Prova (cont)

iii

$$\begin{aligned}
 E[c_1 g_1(X) + c_2 g_2(X)] &= \int_{-\infty}^{\infty} [c_1 g_1(x) + c_2 g_2(x)] f_X(x) dx \\
 &= c_1 \int_{-\infty}^{\infty} g_1(x) f_X(x) dx + \int_{-\infty}^{\infty} c_2 g_2(x) f_X(x) dx \\
 &= c_1 E[g_1(X)] + c_2 E[g_2(X)]
 \end{aligned}$$

iv

Temos que  $g_1(X) \leq g_2(X)$ , logo

$$0 \leq E[g_2(X) - g_1(X)] = E[g_2(X)] - E[g_1(X)].$$

Provas similares podem ser feitas para o caso discreto.

# Valor esperado: teorema

**Teorema** Se  $X$  é uma va, então

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - [E(X)]^2, \text{ dado que } E(X^2) \text{ exista}^2.$$

**Prova** Pela definição de variância e  $E[g(X)]$ , segue que  $\text{Var}(X) = E[X - E(X)]^2$ , e assim,

$$\begin{aligned} \text{Var}(X) &= E[X - E(X)]^2 = E[X^2 - 2XE(X) + (E(X))^2] \\ &= E(X^2) - 2[E(X)]^2 + (E(X))^2 \\ &= E(X^2) - [E(X)]^2. \end{aligned}$$

---

<sup>2</sup>Pode ser mostrado que se  $E(X^2)$  existe então,  $E(X)$  também existe.

## Desigualdade: teorema

**Teorema** Seja  $X$  uma va e  $g(\cdot)$  uma função não-negativa com domínio na reta real, então

$$P(g(X) \geq k) \leq \frac{E[g(X)]}{k}, \quad \text{para todo } k > 0.$$

**Prova** Assuma  $X$  contínua com densidade  $f_X(\cdot)$ , então

$$\begin{aligned} E[g(X)] &= \int_{-\infty}^{\infty} g(x)f_X(x)dx \\ &= \int_{x:g(x)<k} g(x)f_X(x)dx + \int_{x:g(x)\geq k} g(x)f_X(x)dx \\ &\geq \int_{x:g(x)\geq k} g(x)f_X(x)dx \\ &\geq \int_{x:g(x)\geq k} kf_X(x)dx = kP[g(X) \geq k]. \end{aligned}$$

Dividir por  $k$  completa a prova. A prova para o caso discreto é similar.

# Desigualdade: corolário

**Corolário Desigualdade de Chebyshev** Seja  $X$  uma va com variância finita, então

$$P(|X - \mu_X| \geq r\sigma_X) = P\left[(X - \mu_X)^2 \geq r^2\sigma_X^2\right] \leq \frac{1}{r^2}, \quad \text{para todo } r > 0.$$

**Prova** Tome  $g(x) = (x - \mu_X)^2$  e  $k = r^2\sigma_X^2$  no teorema anterior.

# Desigualdade de Chebyshev: comentários

A desigualdade de Chebyshev afirma que  $P(|X - \mu_X| < r\sigma_X) \geq 1 - \frac{1}{r^2}$ . Assim,

$$P(\mu_X - r\sigma_X < X < \mu_X + r\sigma_X) \geq 1 - \frac{1}{r^2}.$$

- Para  $r = 2$ , por exemplo, temos  $P(\mu_X - 2\sigma_X < X < \mu_X + 2\sigma_X) \geq 3/4$ ; ou seja, para qualquer  $va$   $X$  com variância finita pelo menos 3/4 das observações devem estar dentro de dois desvios padrões da sua média.
- Note que a desigualdade nos dá um limite, que não depende da distribuição de  $X$ , para a probabilidade de eventos descritos em termos da  $va$  e sua média e variância.



# Desigualdade de Jensen


**Definição Função convexa** Uma função contínua  $g(\cdot)$  com domínio e contradomínio na reta real é chamada *convexa* se, para todo  $x_0$  na reta real, existe uma linha que passa pelo ponto  $(x_0, g(x_0))$  e está sob ou abaixo do gráfico da função  $g(\cdot)$ .

**Teorema Desigualdade de Jensen** Seja  $X$  uma va com média  $E(X)$ , e seja  $g(\cdot)$  uma função convexa, então

$$E[g(X)] \geq g(E(X)).$$

Em geral,  $E[g(X)] \neq g(E(X))$ . Por exemplo, note que  $g(x) = x^2$  é convexa; portanto a variância de  $X$ , que é  $E(X^2) - [E(X)]^2$ , é não negativa!

# Desigualdade de Jensen: função convexa<sup>3</sup>



**Figura 3:** Representação de função côncava e convexa

<sup>3</sup>Extraído de

[https://www.probabilitycourse.com/chapter6/6\\_2\\_5\\_jensen's\\_inequality.php](https://www.probabilitycourse.com/chapter6/6_2_5_jensen's_inequality.php)

# Momentos e função geradora de momentos

# Momentos: definição

**Definição Momento** Se  $X$  é uma va, o *momento de ordem  $r$*  de  $X$ , geralmente denotado por  $\mu'_r$ , é definido como

$$\mu'_r = E(X^r),$$

se o momento existir. Note que  $\mu'_1 = E(X) = \mu_X$ .

**Definição Momento central** Se  $X$  é uma va, o *momento central de ordem  $r$*  de  $X$ , em torno de  $a$  é definido como  $E((X - a)^r)$ . Se  $a = \mu_X$ , temos o *momento central de ordem  $r$*  de  $X$  em torno de  $\mu_X$ , denotado por  $\mu_r$ , que é


$$\mu_r = E((X - \mu_X)^r).$$

- Note que  $\mu_1 = E(X - \mu_X) = 0$ , e  $\mu_2 = E((X - \mu_X)^2) = \text{Var}(X)$ .
- Todos os momentos ímpares de  $X$  em torno de  $\mu_X$  são 0 se a densidade de  $X$  é simétrica em torno de  $\mu_X$ , dado que tais momentos existam.

## Quantis: definição

**Definição** O quantil  $q$  de uma va  $X$  ou de sua correspondente distribuição é denotado por  $\xi_q$ , e é definido como o menor  $\xi$  satisfazendo  $F_X(\xi) \geq q$ .

Se  $X$  é uma va contínua, o quantil  $q$  de  $X$  é dado pelo menor número  $\xi$  satisfazendo  $F_X(\xi) = q$ .



**Figura 4:** Fonte: Mood et. al (1974)

## Mediana: definição

**Definição** A mediana de uma *va*  $X$ , denotada por  $med_X$ ,  $med(X)$ , ou  $\xi_{0,50}$  é o quantil 0,50.

- Em alguns textos a mediana de  $X$  é definida como qualquer número,  $med(X)$  satisfazendo

$$P(X \leq med(X)) \geq 1/2 \quad \text{e} \quad P(X \geq med(X)) \geq 1/2.$$

- Se  $X$  é uma *va* contínua, então a mediana de  $X$  satisfaz

$$\int_{-\infty}^{med(X)} f_X(x) dx = \frac{1}{2} = \int_{med(X)}^{\infty} f_X(x) dx.$$

# Função geradora de momentos: definição

**Definição** Seja  $X$  uma va com densidade  $f_X(\cdot)$ . O valor esperado de  $e^{tX}$  é definido como a *função geradora de momentos* de  $X$  se o valor esperado existe para  $t$  em algum intervalo  $-h < t < h$ ,  $h > 0$ . A função geradora de momentos, denotada por  $m_X(t)$  ou  $m(t)$ , é

$$m(t) = E(e^{tX}) = \int_{-\infty}^{\infty} e^{tX} f_X(x) dx,$$

se a va  $X$  é contínua e

$$m(t) = E(e^{tX}) = \sum_x e^{tX} f_X(x),$$

se a va  $X$  é discreta.

# Função geradora de momentos

Se derivarmos a função geradora de momentos  $r$  vezes em relação a  $t$ , obtemos

$$\frac{d^r}{dt^r} m(t) = \int_{-\infty}^{\infty} x^r e^{tX} f_X(x) dx,$$

e fazendo  $t \rightarrow 0$ , encontramos

$$\frac{d^r}{dt^r} m(0) = E(X^r) = \mu'_r.$$

Os momentos de uma distribuição podem ser obtidos da função geradora de momentos por diferenciação, o que justifica seu nome.



# Função geradora de momentos

Se substituirmos  $e^{tX}$  por sua expansão em série, obtemos a expansão em série de  $m(t)$  em termos dos momentos de  $f_X(\cdot)$ , isto é,

$$\begin{aligned} m(t) &= E \left[ 1 + Xt + \frac{1}{2!}(Xt)^2 + \frac{1}{3!}(Xt)^3 + \dots \right] \\ &= 1 + \mu'_1 t + \frac{1}{2!}\mu'_2 t^2 + \dots \\ &= \sum_{i=0}^{\infty} \frac{1}{i!} \mu'_i t^i, \end{aligned}$$

do que fica evidente que  $\mu'_r$  pode ser obtida de  $m(t)$ .

# Função geradora de momentos: exemplo

**Exemplo** Seja  $X$  uma va com densidade contínua  $f_X(x) = \lambda e^{-\lambda x} I_{[0, \infty)}(x)$ .

Temos

$$m_X(t) = E(e^{tX}) = \int_0^{\infty} e^{tx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - t}, \quad \text{para } t < \lambda.$$

Assim,

$$m'(t) = \frac{dm_X(t)}{dt} = \frac{\lambda}{(\lambda - t)^2}, \quad \text{logo } m'(0) = E(X) = \frac{1}{\lambda}.$$

# Função geradora de momentos: exemplo

**Exemplo** Seja  $X$  uma va com densidade discreta

$$f_X(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad \text{para } x = 0, 1, 2, \dots$$

Então

$$m_X(t) = E(e^{tX}) = \sum_{x=0}^{\infty} e^{tx} \frac{e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t - 1)}.$$

Utilize a função geradora de momentos acima para encontrar  $E(X)$ ,  $E(X^2)$  e  $Var(X)$ .

## Função geradora de momentos: teorema

**Teorema** Sejam  $X$  e  $Y$  são duas  $va$  com densidades  $f_X(\cdot)$  e  $f_Y(\cdot)$  respectivamente. Suponha que ambas  $m_X(t)$  e  $m_Y(t)$  existam e são iguais para todo  $t$  no intervalo  $-h < t < h$ , para algum  $h > 0$ . Então as duas funções de distribuição acumuladas  $F_X(\cdot)$  e  $F_Y(\cdot)$  são iguais.

- Se a função geradora de momentos de uma  $va$  existe, então esta função geradora de momentos determina de forma única a função de distribuição correspondente.
- Contudo, uma sequência de momentos  $\mu'_1, \mu'_2, \dots$  não determina de forma única uma função de distribuição.

## Função geradora de momentos: exemplo

**Exemplo** Suponha que uma *va*  $X$  tenha função geradora de momentos  $m_X(t) = 1/(1 - t)$  para  $-1 < t < 1$ .

Sabemos que densidade de  $X$  é dada por  $f_X(x) = e^{-x} I_{[0, \infty)}(x)$  pois vimos que  $\lambda e^{-\lambda x} I_{[0, \infty)}(x)$  tem função geradora de momentos  $\lambda/(\lambda - t)$ .