

# Probabilidade e Estatística Matemática I

## Parte 3: Distribuições Univariadas Discretas

Silva, J.L.P.

Junho de 2022


# Distribuição uniforme discreta

# Distribuição uniforme discreta: definição

**Definição** Cada membro da família de funções de densidade discreta

$$f_X(x) = f_X(x; N) = \begin{cases} \frac{1}{N} & \text{para } x = 1, 2, \dots, N \\ 0 & \text{caso contrário} \end{cases} = \frac{1}{N} I_{\{1, 2, \dots, N\}}(x),$$

em que o parâmetro  $N$  é um número positivo inteiro, é dito ter *distribuição uniforme discreta*.



**Figura 1:** Densidade da uniforme discreta. Fonte: Mood et. al (1974)

# Distribuição uniforme discreta: teorema

**Teorema** Se  $X$  tem distribuição uniforme discreta, então

$$E(X) = \frac{(N+1)}{2}, \quad \text{Var}(X) = \frac{(N^2-1)}{12}, \quad \text{e} \quad m_X(t) = E(e^{tX}) = \sum_{j=1}^N e^{jt} \frac{1}{N}.$$

**Prova**

$$E(X) = \sum_{j=1}^N j \frac{1}{N} = \frac{(N+1)}{2}.$$

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 = \sum_{j=1}^N j^2 \frac{1}{N} - \left( \frac{N+1}{2} \right)^2 \\ &= \frac{N(N+1)(2N+1)}{6N} - \frac{(N+1)^2}{4} = \frac{(N^2-1)}{12}. \end{aligned}$$

$$m_X(t) = E(e^{tX}) = \sum_{j=1}^N e^{jt} \frac{1}{N}.$$

## Distribuição uniforme discreta: exemplo

**Exemplo** Lançamos um dado equilibrado e observamos a face que ocorreu. Sendo  $X$  essa variável vemos que  $X$  tem distribuição uniforme discreta com função de probabilidade

$$f_X(x) = P(X = x) = \frac{1}{6}, \quad \text{para } x = 1, 2, \dots, 6.$$

Note que  $E(X) = 7/2 = 3,5$  não é um dos valores possíveis da variável aleatória.


# Distribuições Bernoulli e Binomial

# Distribuição Bernoulli: definição

**Definição** Uma  $va$   $X$  tem *distribuição Bernoulli* se sua função densidade discreta é dada por

$$f_X(x) = f_X(x; p) = \begin{cases} p^x(1-p)^{1-x} & \text{para } x = 0, 1 \\ 0 & \text{caso contrário} \end{cases} = p^x(1-p)^{1-x} I_{\{0,1\}}(x),$$

em que o parâmetro  $p$  satisfaz  $0 \leq p \leq 1$ . Geralmente denota-se  $q = 1 - p$ .



**Figura 2:** Densidade Bernoulli. Fonte: Mood et. al (1974)

# Distribuição Bernoulli: teorema

**Teorema** Se  $X$  tem distribuição Bernoulli, então

$$E(X) = p, \quad \text{Var}(X) = pq, \quad \text{e} \quad m_X(t) = pe^t + q.$$

**Prova**

$$E(X) = 0q + 1p = p.$$

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = 0^2q + 1^2p - p^2 = pq.$$

$$m_X(t) = E(e^{tX}) = q + pe^t.$$



## Distribuição Bernoulli: exemplo

**Exemplo** Para um espaço de probabilidade arbitrário  $(\Omega, \mathcal{A}, P(\cdot))$  e para  $A$  pertencendo a  $\mathcal{A}$ , defina a variável aleatória  $X$  como a função indicadora de  $A$ , isto é,  $X(\omega) = I_A(\omega)$ .

Então  $X$  tem distribuição Bernoulli com parâmetro  $p = P(X = 1) = P(A)$ .

# Distribuição Binomial: definição

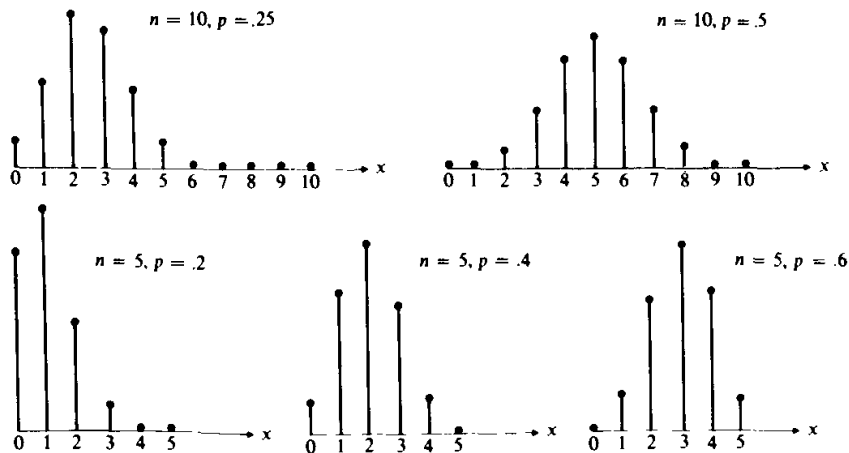
**Definição** Uma  $va$   $X$  tem *distribuição binomial* se sua função densidade discreta é dada por

$$f_X(x) = f_X(x; n, p) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{para } x = 0, 1, \dots, n \\ 0 & \text{caso contrário} \end{cases}$$

$$= \binom{n}{x} p^x (1-p)^{n-x} I_{\{0,1,\dots,n\}}(x),$$

em que o parâmetro  $p$  satisfaz  $0 \leq p \leq 1$  e  $n$  é um inteiro positivo. Geralmente denota-se  $1 - p$  por  $q$ .

# Distribuição Binomial



**Figura 3:** Densidade Binomial. Fonte: Mood et. al (1974)

# Distribuição Binomial: teorema

**Teorema** Se  $X$  tem distribuição binomial, então

$$E(X) = np, \quad \text{Var}(X) = npq, \quad \text{e} \quad m_X(t) = (pe^t + q)^n.$$

**Prova**

$$\begin{aligned} m_X(t) = E(e^{tX}) &= \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} \\ &= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = (pe^t + q)^n \end{aligned}$$

Agora

$$m'_X(t) = npe^t(pe^t + q)^{n-1}$$

$$m''_X(t) = n(n-1)(pe^t)^2(pe^t + q)^{n-2} + npe^t(pe^t + q)^{(n-1)}.$$

# Distribuição Binomial: teorema

**Prova (cont)** Logo,

$$\begin{aligned} E(X) &= m'_X(0) \\ &= np, \end{aligned}$$

e

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 \\ &= m''_X(0) - (np)^2 \\ &= n(n-1)p^2 + np - (np)^2 \\ &= np(1-p). \end{aligned}$$

A distribuição binomial se reduz à Bernoulli quando  $n = 1$ .

## Distribuição Binomial: exemplo

**Exemplo** Considere amostrar com reposição de uma urna contendo  $M$  bolas,  $K$  das quais são defeituosas. Seja  $X$  o número de bolas defeituosas em uma amostra de tamanho  $N$ .

As retiradas individuais são *ensaios de Bernoulli* em que *defeituoso* corresponde a *sucesso*, e o experimento de tirar um amostra de tamanho  $n$  com reposição consiste de  $n$  ensaios de Bernoulli repetidos e independentes em que  $p = P(\text{sucesso}) = k/M$ .

Assim,  $X$  tem distribuição binomial:

$$\binom{n}{x} \left(\frac{K}{M}\right)^x \left(1 - \frac{K}{M}\right)^{n-x}, \quad x = 0, 1, \dots, n.$$

## Distribuição Binomial: exemplo

**Exemplo** A taxa de imunização de uma vacina é de 80%. Se um grupo de 20 pessoas foi vacinado, desejamos saber o comportamento probabilístico do número de pessoas imunizadas desse grupo.

Seja  $X$  a variável de interesse. Para cada pessoa do grupo, a probabilidade de interesse é de 0,80 e admitimos, ainda, independência entre os resultados das várias pessoas vacinadas. Assim,  $X \sim \text{Binomial}(n = 20, p = 0,80)$ .

Por exemplo, a probabilidade de 15 imunizados é dada por

$$f_X(15; 20, 0.80) = P(X = 15) = \binom{20}{15} 0,80^{15} 0,20^{20-15} = 0,175.$$

```
dbinom(x = 15, size = 20, prob = 0.80)
```

```
[1] 0.1745595
```

# Distribuição Binomial: teorema

**Teorema** Seja  $X$  tendo distribuição binomial com densidade  $f_X(x; n, p)$ . Então, para  $x = 0, 1, \dots, n$ :

- i)  $f_X(x-1; n, p) < f_X(x; n, p)$  para  $x < (n+1)p$ ;
- ii)  $f_X(x-1; n, p) > f_X(x; n, p)$  para  $x > (n+1)p$ ;
- iii)  $f_X(x-1; n, p) = f_X(x; n, p)$  para  $x = (n+1)p$  e  $(n+1)p$  inteiro.

## Prova

$$\frac{f_X(x; n, p)}{f_X(x-1; n, p)} = \frac{n-x+1}{x} \cdot \frac{p}{q} = 1 + \frac{(n+1)p - x}{xq},$$

que é maior que 1 se  $x < (n+1)p$ , menor que 1 se  $x > (n+1)p$ , e igual a 1 se o inteiro  $x$  valer  $(n+1)p$ .



# Distribuição Hipergeométrica

# Distribuição Hipergeométrica: definição


**Definição** Uma  $va$   $X$  tem *distribuição hipergeométrica* se sua função densidade discreta é dada por

$$f_X(x; M, K, n) = \begin{cases} \frac{\binom{K}{x} \binom{M-K}{n-x}}{\binom{M}{n}} & \text{para } x = 0, 1, \dots, n \\ 0 & \text{caso contrário} \end{cases}$$

$$= \frac{\binom{K}{x} \binom{M-K}{n-x}}{\binom{M}{n}} I_{\{0,1,\dots,n\}}(x),$$

em que  $M$  é um número inteiro positivo,  $K$  é um inteiro não negativo que vale no máximo  $M$ , e  $n$  é um inteiro que vale no máximo  $M$ .

# Distribuição Hipergeométrica



**Figura 4:** Densidade Hipergeométrica. Fonte: Mood et. al (1974)

# Distribuição Hipergeométrica: teorema

**Teorema** Se  $X$  tem distribuição hipergeométrica, então

$$E(X) = n \cdot \frac{K}{M} \quad \text{e} \quad \text{Var}(X) = n \cdot \frac{K}{M} \cdot \frac{M - K}{M} \cdot \frac{K - n}{M - 1}.$$

**Prova** As provas podem ser consultadas no livro do Mood.

Para a distribuição hipergeométrica, a função geradora de momentos não é útil.

## Distribuição Hipergeométrica: exemplo

**Exemplo** Seja  $X$  o número de itens defeituosos em uma amostra de tamanho  $n$  quando a amostragem é feita sem reposição de uma urna contendo  $M$  bolas,  $K$  das quais são defeituosas.

Então  $X$  tem distribuição hipergeométrica:

$$f_X(x; M, K, n) = P(X = x) = \frac{\binom{K}{x} \binom{M-K}{n-x}}{\binom{M}{n}}$$

## Distribuição Hipergeométrica: exemplo

**Exemplo** Suponha que queremos calcular a probabilidade de que, em certo jogo de cartas, uma mão com 13 cartas contenha exatamente 6 *espadas*. Há  $M = 52$  cartas no total, e podemos assumir que as 13 cartas representam uma amostra de tamanho 13 sem reposição das 52 cartas.

Há um total de 6 espadas (bolas defeituosas no exemplo anterior). Logo, a probabilidade desejada é

$$\frac{\binom{K}{x} \binom{M-K}{n-x}}{\binom{M}{n}} = \frac{\binom{13}{6} \binom{52-13}{13-6}}{\binom{52}{13}} = 0,0416.$$

```
dhyper(x = 6, #número de bolas brancas amostradas sem reposição de
#uma urna contendo bolas pretas e brancas
m = 13, #número de bolas brancas
n = 52 - 13, #número de bolas pretas
k = 13 #número de bolas retiradas da urna
)
```

```
[1] 0.04156398
```

# Distribuição de Poisson

# Distribuição Poisson: definição

**Definição** Uma *va*  $X$  tem *distribuição Poisson* se sua função densidade discreta é dada por

$$f_X(x) = f_X(x; \lambda) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!} & \text{para } x = 0, 1, 2, \dots \\ 0 & \text{caso contrário} \end{cases} = \frac{e^{-\lambda} \lambda^x}{x!} I_{\{0,1,\dots\}}(x),$$

em que o parâmetro  $\lambda$  satisfaz  $\lambda > 0$ .



# Distribuição Poisson




Figura 5: Densidade Poisson. Fonte: Mood et. al (1974)

# Distribuição Poisson: teorema

**Teorema** Se  $X$  tem distribuição Poisson, então

$$E(X) = \lambda, \quad \text{Var}(X) = \lambda, \quad \text{e} \quad m_X(t) = e^{\lambda(e^t-1)}.$$

**Prova**

$$m_X(t) = E(e^{tX}) = \sum_{x=0}^{\infty} \frac{e^{tX} e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t}.$$

Logo,

$$\begin{aligned} m'_X(t) &= \lambda e^{-\lambda} e^t e^{\lambda e^t} \\ m''_X(t) &= \lambda e^{-\lambda} e^t e^{\lambda e^t} (\lambda e^t + 1). \end{aligned}$$

Assim

$$\begin{aligned} E(X) &= m'_X(0) = \lambda \\ \text{Var}(X) &= E(X^2) - [E(X)]^2 = m''_X(0) - \lambda^2 = \lambda(\lambda + 1) - \lambda^2 = \lambda. \end{aligned}$$

## Distribuição Poisson: exemplo

**Exemplo** Suponha que o número médio de chamadas para determinada empresa seja de 30 por hora.

- ❶ Qual a probabilidade de que não cheguem chamadas em um período de 3 minutos?
- ❷ Qual a probabilidade de que chegarão mais de cinco chamadas em um intervalo de 5 minutos?

Assuma que o número de chamadas durante qualquer período de tempo seja Poisson e que o tempo seja medido em minutos. Assim, a *taxa média de ocorrência* é de 0,5 por minuto.

Sendo  $v$  a *taxa média de ocorrência por unidade de tempo*, as probabilidades acima podem ser calculadas de uma distribuição Poisson com parâmetro  $\lambda = vt$ .

# Distribuição Poisson: exemplo

## Exemplo (cont)

(i)

$$P(\text{nenhuma chamada em 3 minutos}) = e^{-(0,5)(3)} = e^{-1,5} = 0.223$$

```
dpois(x = 0, lambda = 0.5*3)
```

```
[1] 0.2231302
```

(ii)

$$P(\text{mais que 5 chamadas em 5 minutos}) = \sum_{k=6}^{\infty} e^{-(0,5)(5)} (2,5)^k / k! = 0.042.$$

```
1 - sum(dpois(x = 0:5, lambda = 0.5*5))
```

```
[1] 0.04202104
```

# Distribuições Geométrica e Binomial Negativa


# Distribuição Geométrica: definição

**Definição** Uma *va*  $X$  tem *distribuição geométrica* (ou *Pascal*) se sua função densidade discreta é dada por

$$f_X(x) = f_X(x; p) = \begin{cases} p(1-p)^x & \text{para } x = 0, 1, 2, \dots \\ 0 & \text{caso contrário} \end{cases} = p(1-p)^x I_{\{0,1,2,\dots\}}(x),$$

em que o parâmetro  $p$  satisfaz  $0 < p \leq 1$ .

# Distribuição Geométrica



**Figura 6:** Densidade Geométrica. Fonte: Mood et. al (1974)

# Distribuição Binomial Negativa: definição

**Definição** Uma  $va$   $X$  tem *distribuição binomial negativa* se sua função densidade discreta é dada por

$$f_X(x) = f_X(x; r, p) = \begin{cases} \binom{r+x-1}{x} p^r q^x = \binom{-r}{x} p^r (-q)^x & \text{para } x = 0, 1, 2, \dots \\ 0 & \text{caso contrário} \end{cases}$$

$$= \binom{r+x-1}{x} p^r q^x I_{\{0,1,2,\dots\}}(x),$$

em que os parâmetros  $r$  e  $p$  satisfazem  $r = 1, 2, 3, \dots$  e  $0 < p \leq 1$  ( $q = 1 - p$ ).

Se tivermos  $r = 1$  na distribuição binomial negativa, então a distribuição geométrica surge como caso particular.



# Distribuição Geométrica: teorema

**Teorema** Se  $X$  tem distribuição geométrica, então

$$E(X) = \frac{q}{p}, \quad \text{Var}(X) = \frac{q}{p^2}, \quad \text{e} \quad m_X(t) = \frac{p}{1 - qe^t}.$$

**Prova** A prova será dada para a distribuição binomial negativa. Como a distribuição geométrica é caso particular da distribuição binomial negativa, o presente teorema é um corolário do teorema a ser provado.

# Distribuição Geométrica: teorema

**Teorema** Se  $X$  tem densidade geométrica com parâmetro  $p$ , então

$$P(X \geq i + j | X \geq i) = P(X \geq j), \quad \text{para } i, j = 0, 1, 2, \dots$$

**Prova**

$$\begin{aligned} P(X \geq i + j | X \geq i) &= \frac{P(X \geq i + j)}{P(X \geq i)} \\ &= \frac{\sum_{x=i+j}^{\infty} p(1-p)^x}{\sum_{x=i}^{\infty} p(1-p)^x} = \frac{(1-p)^{i+j}}{(1-p)^i} \\ &= (1-p)^j \\ &= P(X \geq j). \end{aligned}$$

## Distribuição Geométrica: exemplo

**Exemplo** Considere uma sequência de ensaios Bernoulli independentes, cada um com probabilidade  $p$  de sucesso. Seja  $X$  a variável aleatória que representa o número de ensaios necessários antes do primeiro sucesso<sup>1</sup>. Então  $X$  terá distribuição geométrica.

Note que o primeiro sucesso ocorrerá no ensaio  $x + 1$  se tal ensaio retornar sucesso e os primeiros  $x$  ensaios retornarem fracasso. Por independência,  $x$  falhas sucessivas seguidas por um fracasso tem probabilidade  $(1 - p)^x p$ .

No contexto deste exemplo, o teorema diz que a probabilidade de que  $i + j$  ensaios sejam necessários antes do primeiro sucesso, dado que houve  $i$  falhas sucessivas, é igual à probabilidade não condicional de que pelo menos  $j$  ensaios sejam necessários antes do primeiro sucesso.

Tal propriedade é conhecida como *falta de memória*.

---

<sup>1</sup>Em outras palavras,  $X$  representa o número de falhas antes de observarmos o primeiro sucesso.

## Distribuição Geométrica: exemplo

**Exemplo** Uma linha de fabricação de um equipamento de precisão é interrompida na primeira ocorrência de um defeito. A partir da manutenção, o equipamento tem probabilidade de 0,01 de apresentar defeito em um dia qualquer.

Deseja-se planejar o cronograma de manutenção preventiva e, para tal, decidiu-se avaliar probabilisticamente a espera até a produção ser interrompida. Seja  $X$  a  $va$  que conta o número de dias que antecedem a interrupção. Admitindo que o desempenho, nos sucessivos dias, sejam independentes, temos

$$f_X(x; p) = P(X = x) = 0,01 \times 0,99^x, \quad x = 0, 1, 2, \dots$$

Por ex., para interrupção no sexto dia temos  $P(X = 5) = 0,01 \times 0,99^5 = 0,0095$ .

```
dgeom(x = 5, p = 0.01)
```

```
[1] 0.0095099
```

## Distribuição Geométrica: exemplo

**Exemplo (cont)** Qual seria o intervalo ideal para uma manutenção preventiva se desejamos uma probabilidade de, pelo menos, 0,90 de que o defeito não ocorrerá?

Precisamos determinar quantos dias são necessários para acumular uma probabilidade de defeito próxima de 0,10. Ou obter  $k$  tal que

$$P(X \leq k) = 1 - P(X > k) = 1 - 0,99^{k+1} \approx 0,10.$$

Obtemos  $P(X \leq 9) = 0,0956$  e  $P(X \leq 10) = 0,1047$ . Assim, a manutenção preventiva deverá ser feita após 9 dias de operação. Dessa forma, teremos probabilidade de 0,9044 de um defeito não ocorrer entre essas manutenções.

```
c(sum(dgeom(x = 0:9, p = 0.01)), sum(dgeom(x = 0:10, p = 0.01)))
```

```
[1] 0.09561792 0.10466175
```

# Distribuição Geométrica: observação

Alguns autores definem a distribuição geométrica assumindo 1 (no lugar de 0) como menor ponto de massa.

A densidade tem a forma

$$f(x; p) = p(1 - p)^{x-1} I_{\{1,2,\dots\}}(x),$$

com média  $1/p$ , variância  $q/p^2$  e função geradora de momentos  $pe^t/(1 - qe^t)$ .

Assim, a variável aleatória  $X$  representa o número de ensaios necessários para se obter o primeiro sucesso.

# Distribuição Binomial Negativa: teorema

**Teorema** Se  $X$  tem distribuição binomial negativa, então

$$E(X) = \frac{rq}{p}, \quad \text{Var}(X) = \frac{rq}{p^2}, \quad \text{e} \quad m_X(t) = \left( \frac{p}{1 - qe^t} \right)^r.$$

**Prova**

$$\begin{aligned} m_X(t) &= E(e^{tX}) = \sum_{x=0}^{\infty} e^{tx} \binom{-r}{x} p^r (-q)^x \\ &= \sum_{x=0}^{\infty} \binom{-r}{x} p^r (-qe^t)^x = \left( \frac{p}{1 - qe^t} \right)^r \end{aligned}$$

Agora

$$\begin{aligned} m'_X(t) &= p^r (-r)(1 - qe^t)^{-r-1} (-qe^t) \\ m''_X(t) &= rqp^r [q(r+1)e^{2t}(1 - qe^t)^{-r-2} + e^t(1 - qe^t)^{-r-1}]. \end{aligned}$$

# Distribuição Binomial Negativa: teorema

**Prova (cont)** Logo,

$$E(X) = m'_X(0) = \frac{rq}{p},$$

e

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 = m''_X(0) - \left(\frac{rq}{p}\right)^2 \\ &= rqp^r[qp^{-r-2}(r+1) + p^{-r-1}] - \left(\frac{rq}{p}\right)^2 \\ &= \frac{rq^2}{p^2} + \frac{rq}{p} = \frac{rq}{p^2}. \end{aligned}$$

Diferente da distribuição Poisson, em que a média e variância são iguais, a variância da distribuição binomial negativa é maior que sua média.



# Distribuição Binomial Negativa: exemplo

**Exemplo** Considere uma sequência de ensaios Bernoulli independentes, cada um com probabilidade  $p$  de sucesso. Seja a variável aleatória  $X$  o número de falhas antes do  $r$ -ésimo sucesso.

Então  $X$  tem distribuição binomial negativa. Para ver isso, note que o último ensaio deve resultar em um sucesso, tendo probabilidade  $p$ . Entre os  $x + r - 1$  ensaios deve haver  $r - 1$  sucessos e  $x$  falhas, o que pode ser calculado pela Binomial com parâmetros  $x + r - 1$  e  $p$ .

Tal probabilidade é

$$\binom{x + r - 1}{r - 1} p^{r-1} q^x = \binom{r + x - 1}{x} p^{r-1} q^x,$$

que, multiplicado por  $p$ , produz o resultado desejado.

# Outras Distribuições Discretas

## Outras Distribuições Discretas: truncamento

Novas famílias de distribuições discretas podem ser formadas por vários procesos. Um deles é o *truncamento*.

O processo será ilustrado para a *distribuição de Poisson truncada em 0*. Suponha que o valor 0 não possa ser observado, embora a distribuição de Poisson pareça um modelo adequado.

A probabilidade no ponto 0 é distribuída proporcionalmente aos outros pontos de massa, retornando a família de densidades

$$f_X(x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!(1-e^{-\lambda})} & \text{para } x = 1, 2, \dots \\ 0 & \text{caso contrário} \end{cases}$$

## Outras Distribuições Discretas: censura

Outro processo de obtenção de uma nova família de densidades também pode ser ilustrado com a distribuição de Poisson.

Suponha que a variável aleatória  $X$ , representando algum tipo de contagem, tenha distribuição de Poisson. Se o instrumento de medida é tal que não permite contagens além do 2, a variável aleatória tem densidade dada por

$z$	0	1	2
$f(z)$	$e^{-\lambda}$	$\lambda e^{-\lambda}$	$1 - e^{-\lambda} - \lambda e^{-\lambda}$

# Distribuição Beta-binomial: definição

**Definição** A *distribuição beta-binomial* tem densidade discreta

$$f_X(x) = f(x; n, \alpha, \beta) = \binom{n}{x} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(x + \alpha)\Gamma(n + \beta - x)}{\Gamma(n + \alpha + \beta)} I_{\{0,1,2,\dots,n\}}(x),$$

em que  $n$  é um inteiro não negativo,  $\alpha > 0$ ,  $\beta > 0$ .

$\Gamma(m)$  é a função gamma  $\Gamma(m) = \int_0^\infty x^{m-1} e^{-x} dx$  para  $m > 0$ . Tem-se

$$E(X) = \frac{n\alpha}{\alpha + \beta} \quad \text{e} \quad \text{Var}(X) = \frac{n\alpha\beta(n + \alpha + \beta)}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Tal distribuição possui os mesmos pontos de massa da distribuição binomial. Se  $\alpha = \beta = 1$ , então a distribuição beta-binomial se reduz à distribuição uniforme nos inteiros  $0, 1, \dots, n$ .

# Distribuição Logarítmica: definição

**Definição** A distribuição com função de densidade discreta

$$f_X(x) = f_X(x; p) = \begin{cases} \frac{q^x}{-x \log p} & \text{para } x = 1, 2, \dots \\ 0 & \text{caso contrário} \end{cases} = \frac{q^x}{-x \log p} I_{\{1, 2, \dots\}}(x),$$

em que o parâmetro  $p$  satisfaz  $0 < p < 1$  e  $q = 1 - p$  é chamada de *distribuição logarítmica*.

A distribuição logarítmica tem

$$E(X) = \frac{q}{-p \log p} \quad \text{e} \quad \text{Var}(X) = \frac{q(q + \log p)}{-(p \log p)^2}.$$